به نام خداوند بخشنده مهربان

المپیاد هوش مصنوعی

باشگاه دانش‌پژوهان جوان

تابستان ۱۴۰۵

آزمون تئوری اول

مدت پاسخ‌گویی: ۲۱۰ دقیقه

۱ طراحی و تحلیل شبکه کانولوشنی برای خودروی خودران - ۲۵ نمره

فرض کنید در حال طراحی یک شبکه عصبی کانولوشنی [۱] برای یک سیستم خودروی خودران هستید. تصاویر جاده باید در ۱۰ دسته مختلف (مانند بزرگراه، چهارراه، گذرگاه پیاده، تونل و ...) طبقه‌بندی شوند. اندازه تصاویر ورودی برابر با $۳ \times ۲۲۴ \times ۲۲۴$ است. معماری شبکه به صورت زیر است:

- لایه ۱ (Conv1): ۶۴ فیلتر با اندازه ۷×۷، گام [۲] ۲ و پدینگ [۳] ۳
- لایه ۲ (Conv2): ۱۲۸ فیلتر با اندازه ۳×۳، گام ۱ و پدینگ ۱
- لایه ۳ (MaxPool): اندازه ۳×۳، گام ۲
- لایه ۴ (Conv3): ۲۵۶ فیلتر با اندازه ۳×۳، گام ۲ و پدینگ ۱
- لایه ۵ (Fully Connected): ۱۰ خروجی

(الف) ۳ نمره تعداد پارامترهای آخرین لایه این شبکه را با انجام محاسبات لازم پیدا کنید.

(ب) ۴ نمره اگر لایه کانولوشن سوم با کانولوشن تفکیک‌پذیر عمق [۴] جایگزین شود، تعداد پارامترها به چه میزان کاهش پیدا می‌کند؟

(ج) ۸ نمره فرض کنید شبکه آموزش‌دیده عملکرد خوبی روی اشیایی که در مرکز تصویر هستند دارد، اما برای اشیایی که در مکان‌های غیرمعمول ظاهر می‌شوند عملکرد ضعیفی نشان می‌دهد.

۱) دلیل این اتفاق را مشخص کنید. (چرا با وجود اینکه لایه‌های کانولوشنی خاصیت جابه‌جایی هم‌ارز [۵] دارند، این اتفاق رخ می‌دهد؟)

۲) یک راه‌حل برای رفع این مشکل بدون تغییر معماری ارائه دهید.

(د) ۵ نمره فرض کنید دادهٔ محدودی برای تسک تشخیص اشیاء [۶] در اختیار داریم و مطابق روش Fast R-CNN می‌خواهیم یک شبکه متشکل از لایه‌های تمام‌متصل [۷] برای تنظیم Bounding Box و تشخیص دستهٔ اشیاء، روی خروجی‌های لایهٔ Conv3 استفاده کنیم. اگر ورودی این لایه‌ی تماما متصل ۱۰۲۴ بُعدی باشد، مشخص کنید حاصل ROI-Pooling باید چه طول و عرضی داشته باشد؟

(ه) ۵ نمره اگر به جای شبکه کانولوشنی (CNN) از مدل بینایی تبدیل (ViT) استفاده شود، معمولاً حافظه GPU بیشتری نیاز دارد. مهم‌ترین دلیل را بیان کنید.

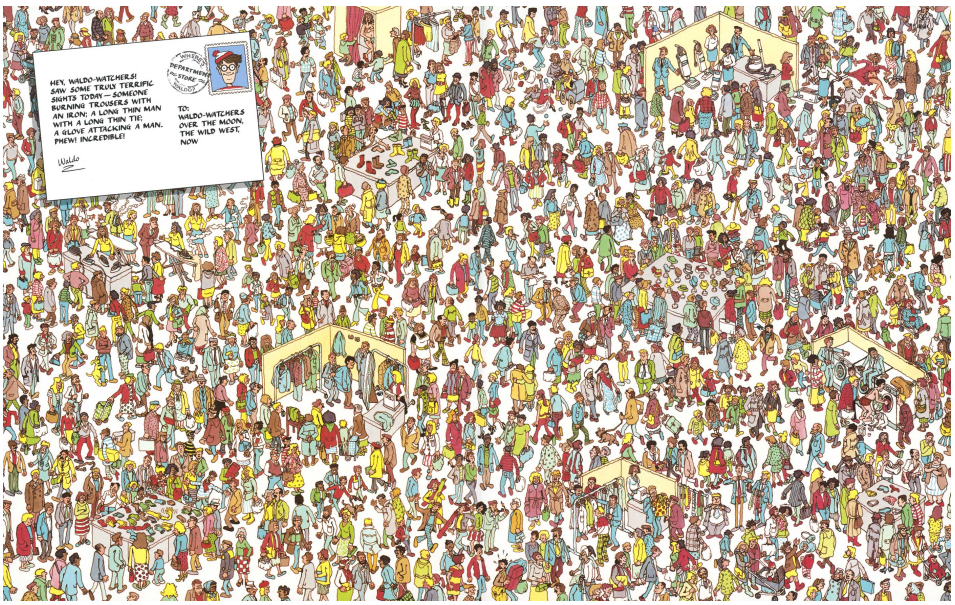
---

[۱] CNN
[۲] Stride
[۳] Padding
[۴] Depth-wise Separable Convolution
[۵] Translation Equivariance
[۶] Object Detection
[۷] Fully Connected

۲ یافتن «والدو» در تصاویر بسیار بزرگ - ۳۰ نمره

صورت مسئله

در کتاب معماهای مصور «والدو کجاست؟» (Where's Waldo?)، هدف پیدا کردن شخصیت اصلی داستان در یک تصویر شلوغ است. تصویر معمولاً بسیار بزرگ بوده و والدو مانند سوزنی در انبار کاه میان تعداد زیادی شیء دیگر پنهان شده است.



نمونه‌ای از صحنه‌های پرجزئیات معماهای مصور «والدو کجاست؟»

فرض کنید برای حل این مسئله یک دادگان آموزشی شامل ۱۰۰۰ تصویر اسکن‌شده از کتاب‌های والدو در اختیار داریم. هر تصویر ابعاد زیر را دارد:

$$W = ۲۰۰,۰۰۰, \quad H = ۱۰۰,۰۰۰$$

یعنی هر تصویر تقریباً ۲۰۰,۰۰۰ × ۱۰۰,۰۰۰ پیکسل است. برای هر تصویر فقط یک برچسب باینری کلی داریم:

$$y \in \{۰, ۱\}$$

که نشان می‌دهد آیا والدو در کل آن تصویر وجود دارد یا خیر (برچسب محلی (Local Label) یا مکان دقیق در ابتدا مشخص نیست). همچنین فرض کنید اندازه معمول والدو در تصاویر تقریباً ۶۴ × ۶۴ پیکسل است.

تعاریف و نمادگذاری

- **کاشی**[۸]: زیرناحیهٔ مربعی از تصویر که با افراز[۹] تصویر به دست می‌آید.
- **تعداد کاشی‌ها (N)**: تعداد کاشی‌های استخراج‌شده از یک تصویر.
- **امتیاز کاشی**[۱۰] **(s_i)**: خروجی مدل برای کاشی i که به‌معنای احتمال وجود والدو در آن کاشی است و $s_i \in [۰, ۱]$.
- **تجمیع**[۱۱] **با عملگر بیشینه**[۱۲]: پیش‌بینی سراسری $\hat{y}$ از تجمیع امتیاز کاشی‌ها به دست می‌آید؛ در روش پیش‌فرض:

$$\hat{y} = \max_{i=۱,\dots,N} s_i$$

- **تابع خطا**[۱۳] **آنتروپی متقاطع دوتایی**[۱۴]:

$$\mathcal{L} = -\left[y \log \hat{y} + (۱ - y) \log(۱ - \hat{y})\right]$$

- **معیار IoU**: نسبت مساحت اشتراک[۱۵] دو کادر[۱۶] به مساحت اجتماع[۱۷] آن‌ها؛ $\text{IoU} \in [۰, ۱]$ و مقدار ۱ به‌معنای انطباق کامل است.

[۸] Tile / Patch
[۹] Partitioning
[۱۰] Tile Score
[۱۱] Aggregation
[۱۲] Max Operator
[۱۳] Loss Function
[۱۴] Binary Cross-Entropy
[۱۵] Intersection
[۱۶] Bounding Box
[۱۷] Union

- **منجمدسازی**[۱۸] **بدنه:** عبارت $\nabla_\phi = ۰$ یعنی وزن‌های بدنهٔ ویژگی‌گیر[۱۹] یعنی ϕ در جریان آموزش به‌روزرسانی نمی‌شوند و گرادیان به آن‌ها منتقل نمی‌شود.
- **خلاصهٔ نمادها:** W, H: عرض و ارتفاع تصویر؛ y: برچسب باینری کلی؛ θ: وزن‌های مدل؛ ϕ: بدنهٔ ویژگی‌گیر؛ ψ: سرِ پیش‌بینی کادر[۲۰]؛ z: بردار ویژگی[۲۱]؛ $\hat{b}$: کادر تخمینی[۲۲]؛ b^*: کادر واقعی[۲۳].

پرسش‌ها

با توجه به صورت مسئله و تعاریف بالا، به پرسش‌های زیر پاسخ دهید.

(الف) ۳ نمره توضیح دهید چرا شبکه‌های تمام‌متصل یا کانولوشنی استاندارد که کل تصویر را به صورت یکجا به عنوان ورودی دریافت می‌کنند، در مواجهه با این ابعاد با شکست مواجه می‌شوند.

(ب) ۳ نمره چرا راه‌حل سادهٔ کاهش وضوح[۲۴] تصویر به ابعاد متعارف (مثلاً ۱۰۲۴×۱۰۲۴) پیش از ورود به شبکه، برای این مسئله مناسب نیست؟

(ج) ۳ نمره با توجه به اینکه کوچک‌سازی امکان‌پذیر نیست، یک ایدهٔ طبیعی این است که تصویر را به کاشی‌های کوچک افراز کنیم و مدلی آموزش دهیم که وجود والدو را در هر کاشی جداگانه حساب کند. توضیح دهید که چرا این ایده در حل مسئلهٔ والدو مفید است و چرا در حل مسائل دیگر (مثل شناسایی اشیا[۲۵]) لزوماً مفید نیست.

(د) ۴ نمره یکی از چالش‌های ایدهٔ کاشی‌بندی این است که والدو ممکن است بین دو کاشی باشد و دقیقاً و کامل در یک کاشی قرار نداشته باشد. راهکار شما برای حل چالش قرار گرفتن والدو در مرز کاشی‌ها چیست؟

(ه) ۴ نمره همان‌طور که در بخش تعاریف آمد، مدل سبک به ازای هر کاشی امتیازی مانند $s_i \in [۰, ۱]$ تولید می‌کند و تجمیع پیش‌فرض با عملگر بیشینه ($\hat{y} = \max_{i=۱,\dots,N} s_i$) انجام می‌شود. حال با استفاده از تابع خطای آنتروپی متقاطع دوتایی معرفی‌شده در بخش تعاریف:

$$\mathcal{L} = -[y \log \hat{y} + (۱ - y) \log(۱ - \hat{y})], \quad \hat{y} = \max_{i=۱,\dots,N} s_i$$

مشتق تابع خطا را نسبت به وزن‌های مدل (θ) به دست آورید و نشان دهید چرا این عملگر در شروع آموزش با شکست مواجه می‌شود.

(و) ۳ نمره برای رفع این مشکل چه راه‌حلی پیشنهاد می‌کنید؟

(ز) ۴ نمره فرض کنید مدل با ایده‌های بالا به دقت مناسبی رسیده و حال می‌خواهیم مکان دقیق والدو را با یک کادر تخمین بزنیم. بدنهٔ شبکه را ثابت منجمد کرده ($\nabla_\phi = ۰$) و یک شبکهٔ تمام‌متصل جدید h_ψ روی بردار ویژگی قرار می‌دهیم:

$$z = \phi(x), \quad \hat{b} = h_\psi(z)$$

که خروجی آن کادر تخمینی $\hat{b} = (\hat{x}_۱, \hat{y}_۱, \hat{x}_۲, \hat{y}_۲)$ است. کادر واقعی با $b^* = (x^*_۱, y^*_۱, x^*_۲, y^*_۲)$ مشخص شده است. معیار ارزیابی شباهت دو مستطیل IoU است و اولین ایدهٔ ما این است که مستقیماً تابع خطای $\mathcal{L}_{\text{IoU}} = ۱ - \text{IoU}(\hat{b}, b^*)$ را بهینه کنیم. فرمول مساحت اشتراک (I) و مساحت اجتماع (U) را برحسب مختصات گوشه‌ها بنویسید.

(ح) ۶ نمره در همان تنظیمات بند (ز)، مشتق این تابع خطا نسبت به مختصات تخمینی را در وضعیتی که کادر تخمینی هیچ اشتراکی با کادر واقعی ندارد ($\hat{b} \cap b^* = \emptyset$) تحلیل کنید و نقص عملکرد آن را شرح دهید. چه اصلاحاتی را در تابع خطا پیشنهاد می‌کنید؟

---

[۱۸] Freezing
[۱۹] Backbone
[۲۰] Bounding-Box Prediction Head
[۲۱] Feature Vector
[۲۲] Predicted Box
[۲۳] Ground-Truth Box
[۲۴] Downsampling
[۲۵] Object Detection

۳ تحلیل مقاومت مدل در برابر اختلال ورودی - ۲۰ نمره

تعاریف و روابط مورد نیاز

نرم‌ها: برای بردار $v \in \mathbb{R}^n$:

$$\|v\|_1 = \sum_{i=1}^{n} |v_i|, \qquad \|v\|_2 = \sqrt{\sum_{i=1}^{n} v_i^2}, \qquad \|v\|_\infty = \max_i |v_i|$$

رابطه‌ی دوگانگی L_2: برای هر بردار g و هر $\varepsilon > 0$:

$$\min_{\|\delta\|_2 \le \varepsilon} g^\top \delta = -\varepsilon \, \|g\|_2$$

صورت مسئله

یک مدل عمیق با سرِ خطی برای دسته‌بندی تصاویر در یک سامانه‌ی حساس به‌کار رفته است. خروجی مدل به شکل زیر است:

$$f_\theta(x) = w^\top h_\theta(x) + b$$

که در آن $h_\theta(x)$ بردار نمایش [۲۶] استخراج‌شده توسط شبکه، w بردار وزن‌های لایه‌ی آخر، و b عرض از مبدأ است. برای هر نمونه‌ی برچسب‌دار $(x,\, y)$ با $y \in \{-1,\, +1\}$، حاشیه [۲۷] به صورت زیر تعریف می‌شود:

$$m(x) = y \, f_\theta(x)$$

مقدار مثبت $m(x)$ به معنای پیش‌بینی صحیح است.
یک مهاجم می‌تواند اختلال [۲۸] δ را به تصویر آزمون x_0 اضافه کند، به‌طوری‌که تغییر هر پیکسل نرمال‌شده محدود باشد:

$$\|\delta\|_\infty \le \varepsilon$$

از آنجا که بهینه‌سازی دقیق در سراسر شبکه‌ی عمیق دشوار است، در همسایگی x_0 از تقریب مرتبه‌ی اول [۲۹] استفاده می‌کنیم:

$$m(x_0 + \delta) \approx m_0 + g^\top \delta, \qquad m_0 := m(x_0) > 0, \quad g := \nabla_x m(x_0)$$

پرسش‌ها

با توجه به صورت مسئله‌ی بالا، به پرسش‌های زیر پاسخ دهید.

(الف) ۵ نمره نشان دهید:

$$\min_{\|\delta\|_\infty \le \varepsilon} \; (m_0 + g^\top \delta) \;=\; m_0 - \varepsilon \, \|g\|_1$$

و سپس بزرگ‌ترین ε را بیابید که تضمین کند حاشیه‌ی خطی‌شده برای هر اختلال مجاز مثبت باقی می‌ماند.

(ب) ۵ نمره اکنون فرض کنید در نقطه‌ی x_0، دو شبکه‌ی A و B حاشیه‌ی یکسان $m_0 = 0.24$ دارند، اما گرادیان‌های آن‌ها متفاوت است:

$$g_A = (1.2,\; 0,\; 0,\; 0), \qquad g_B = (0.35,\; 0.35,\; 0.35,\; 0.35)$$

در این قسمت، مقاومت دو شبکه را در برابر دو نوع حمله‌ی خصمانه [۳۰] بررسی می‌کنیم:

- **حمله‌ی L_∞:** مهاجم مختار است هر پیکسل را مستقلاً تا سقف ε تغییر دهد، یعنی $\|\delta\|_\infty \le \varepsilon$. این مدل، بدترین سناریوی تغییرات پراکنده و کوچک در تمام پیکسل‌ها را توصیف می‌کند.
- **حمله‌ی L_2:** مهاجم تنها بر اندازه‌ی کلی اختلال محدودیت دارد، یعنی $\|\delta\|_2 \le \varepsilon$. در این مدل، مهاجم می‌تواند تغییرات بزرگ‌تری را روی تعداد کمتری پیکسل متمرکز کند.

با استفاده از نتیجه‌ی قسمت (الف) برای حمله‌ی L_∞ و رابطه‌ی دوگانگی L_2 برای حمله‌ی L_2، شعاع مقاومت خطی هر دو شبکه را در هر دو مدل تهدید [۳۱] محاسبه کنید. کدام شبکه در برابر حمله‌ی L_∞ مقاوم‌تر است؟ کدام در برابر حمله‌ی L_2؟
شعاع مقاومت خطی [۳۲]: بزرگ‌ترین مقدار ε که به ازای آن، حاشیه‌ی خطی‌شده تحت هر اختلال مجاز همچنان مثبت باقی بماند.

(ج) ۵ نمره عبارت «شبکه‌ی A در برابر حملات خصمانه مقاوم‌تر است» به‌تنهایی گزاره‌ی کاملی نیست. به اختصار توضیح دهید چرا، و چه اطلاعاتی برای ادعای دقیق‌تر لازم است.

---

[۲۶] Representation
[۲۷] Margin
[۲۸] Perturbation
[۲۹] First-Order Approximation
[۳۰] Adversarial Attack
[۳۱] Threat Model
[۳۲] Linear Robustness Radius

(د) ۵ نمره در ادامه‌ی تحلیل، اکنون یک قید اضافی به مسئله‌ی مهاجم تحمیل می‌کنیم: فرض کنید سامانه‌ی دفاعی، میانگین روشنایی تصویر را پایش می‌کند و مهاجم برای نامحسوس ماندن، علاوه بر قید رایج $|\delta_i| \le \varepsilon$، باید میانگین اختلال را صفر نگه دارد:

$$\max_{\delta \in \mathbb{R}^{۲m}} \; g^\top \delta \qquad \text{to subject} \quad |\delta_i| \le \varepsilon \;\; (۱ \le i \le ۲m), \quad \sum_{i=۱}^{۲m} \delta_i = ۰$$

فرض کنید مؤلفه‌های g به‌صورت صعودی مرتب شده‌اند:

$$g_{(۱)} < g_{(۲)} < \cdots < g_{(۲m)}.$$

جواب بهینه را در این حالت بیابید و مقدار متناظر δ ای که منجر به این جواب بهینه می‌شود را حساب کنید.

۴ رگرسیون خطی با نویز گاوسی - ۲۵ نمره

هر نمونه شامل بردار $\tilde{\mathbf{x}} \in \mathbb{R}^{d+1}$[۳۳] است که مولفه اول آن ثابت و برابر ۱ است. فضای ویژگی[۳۴] را با نمایش زیر در نظر بگیرید. هدف به‌صورت نویزی تعریف شده است:

$$y = \mathbf{w}^{*\top}\tilde{\mathbf{x}} + \varepsilon, \qquad \mathbf{w}^* \in \mathbb{R}^{d+1}, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

نویز ε تصادفی است و برای هر ورودی مقدار متفاوتی دارد و مستقل از (x, y) است. همچنین بردار ضرایب حقیقی $\mathbf{w}^*$[۳۵] ثابت است. برای مجموعه داده $\mathcal{D} = \{(\tilde{\mathbf{x}}_1, y_1), \dots, (\tilde{\mathbf{x}}_N, y_N)\}$، ماتریس طراحی $\mathbf{X} \in \mathbb{R}^{N\times(d+1)}$[۳۶] و بردار خروجی $\mathbf{y} \in \mathbb{R}^N$ رابطه زیر برقرار است:

$$\mathbf{y} = \mathbf{X}\mathbf{w}^* + \varepsilon$$

فرض کنید $\mathbf{X}^\top\mathbf{X}$ معکوس‌پذیر است. در این سؤال از برآوردگر کمینه مربعات خطی برای یافتن بردار وزن استفاده می‌کنیم. این مسئله مجموع مربعات اختلاف بین خروجی مدل و مقادیر واقعی را کمینه می‌کند. وزن بهینه از این روش را $\mathbf{w}_{\text{lin}}$ می‌نامیم. خروجی پیش‌بینی‌شده را $\hat{\mathbf{y}}$ می‌نامیم که از رابطه زیر حساب می‌شود:

$$\hat{\mathbf{y}} := \mathbf{X}\mathbf{w}_{\text{lin}}$$

برای ارزیابی کیفیت برازش مدل[۳۷] روی داده‌های آموزشی، معیاری به نام خطای درون‌نمونه[۳۸] تعریف می‌شود که میانگین مربعات اختلاف بین مقادیر واقعی مشاهده‌شده و مقادیر پیش‌بینی‌شده است:

$$E_{\text{in}}(\mathbf{w}_{\text{lin}}) := \frac{1}{N}\|\mathbf{X}\mathbf{w}_{\text{lin}} - \mathbf{y}\|^2$$

(الف) ۴ نمره ثابت کنید ماتریس $\mathbf{H} := \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top \in \mathbb{R}^{N\times N}$ در ویژگی‌های زیر صدق می‌کند:

$$\mathbf{H}^\top = \mathbf{H} \quad \text{symmetric}, \qquad \mathbf{H}^2 = \mathbf{H} \quad \text{idempotent}, \qquad \text{tr}(\mathbf{H}) = d + 1.$$

(ب) ۴ نمره نشان دهید:

$$\hat{\mathbf{y}} = \mathbf{X}\mathbf{w}^* + \mathbf{H}\varepsilon, \qquad \hat{\mathbf{y}} - \mathbf{y} = (\mathbf{H} - \mathbf{I})\varepsilon.$$

(ج) ۴ نمره ثابت کنید:

$$E_{\text{in}}(\mathbf{w}_{\text{lin}}) = \frac{1}{N}\varepsilon^\top(\mathbf{I} - \mathbf{H})\varepsilon.$$

(د) ۵ نمره با استفاده از بسط $\varepsilon^\top(\mathbf{I} - \mathbf{H})\varepsilon = \sum_{i,j}(\mathbf{I} - \mathbf{H})_{ij}\varepsilon_i\varepsilon_j$ و تقارن ماتریس $\mathbf{H}$ ثابت کنید:

$$\mathbb{E}_{\mathcal{D}}[E_{\text{in}}(\mathbf{w}_{\text{lin}})] = \sigma^2\left(1 - \frac{d+1}{N}\right).$$

نماد $\mathbb{E}_{\mathcal{D}}[\cdot]$ امید ریاضی نسبت به متغیر تصادفی نویز ε را نشان می‌دهد. در این مسئله ماتریس‌های $\mathbf{X}$ و $\mathbf{y}$ به عنوان کمیت ثابت فرض می‌شوند.

(ه) ۵ نمره در این بخش، فرض استقلال نویزها که در ابتدای سؤال مطرح شد را بردارید و فرض کنید ε برداری تصادفی با میانگین صفر و ماتریس کوواریانس Σ (متقارن، نیمه‌معین مثبت و مستقل از $\mathbf{X}$) است. ثابت کنید:

$$\mathbb{E}_{\mathcal{D}}[E_{\text{in}}(\mathbf{w}_{\text{lin}})] = \frac{1}{N}\,\text{tr}\left((\mathbf{I} - \mathbf{H})\Sigma\right).$$

(دقت کنید که با جایگذاری $\Sigma = \sigma^2\mathbf{I}$ در این رابطه، فرمول بخش (د) به‌دست می‌آید.)

(و) ۳ نمره اگر $N = d + 1$ باشد، مقدار $E_{\text{in}}(\mathbf{w}_{\text{lin}})$ چقدر است؟ (دقت کنید که در این حالت خود E_{in} را حساب کنید نه امید آن را.) نتیجه به دست آمده را با توجه به اینکه داده‌های آموزشی دارای نویز هستند توضیح دهید. (به زبان درجات آزادی[۳۹] و بیش‌برازش[۴۰]).

---

[۳۳] feature vector
[۳۴] feature space
[۳۵] true coefficient vector
[۳۶] design matrix
[۳۷] model fit
[۳۸] in-sample error
[۳۹] degrees of freedom
[۴۰] overfitting