به نام خداوند بخشنده مهربان

المپیاد هوش مصنوعی

باشگاه دانش‌پژوهان جوان

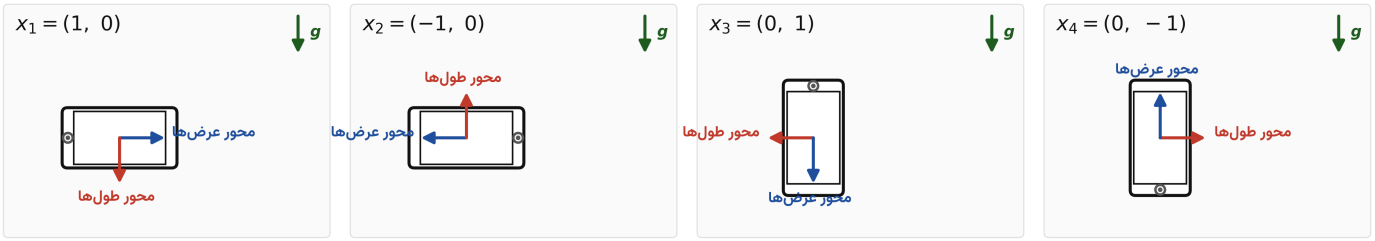
تابستان ۱۴۰۵

نمره کل: ۱۲۰ | **آزمون تئوری دوم** | مدت پاسخ‌گویی: ۲۷۰ دقیقه

۱ تشخیص جهت‌یابی صفحه با روش Kernel PCA - ۲۱ نمره

فرض کنید یک شتاب‌سنج گوشی داریم که جهت نیروی جاذبه را نسبت به صفحه گزارش می‌کند. این بردار در دستگاه مختصات صفحه به طول واحد است. با چرخش ۱۸۰ درجه گوشی، این بردار قرینه می‌شود؛ یعنی x به $-x$ تبدیل می‌شود. هدف این است که تنها بر اساس همین بردارها و بدون استفاده از برچسب‌ها، تشخیص دهیم که گوشی در حالت افقی است یا عمودی.
اندازه‌گیری‌های زیر را در نظر بگیرید:

$$x_۱ = (۱, ۰), \quad x_۲ = (-۱, ۰), \quad x_۳ = (۰, ۱), \quad x_۴ = (۰, -۱).$$



وضعیت گوشی در هر یک از چهار اندازه‌گیری $x_۱$ تا $x_۴$؛ g جهت نیروی جاذبه است.

دو بردار سمت چپ مربوط به دو حالت افقی گوشی و دو بردار سمت راست مربوط به دو حالت عمودی آن هستند. توجه کنید که چرخش ۱۸۰ درجه در تصمیم‌گیری بی‌اثر است؛ بنابراین x و $-x$ باید به یک جهت‌یابی صفحه[۱] منجر شوند.

الف) (۶.۵ نمره) نشان دهید میانگین این چهار بردار صفر است و ماتریس کواریانس آن‌ها برابر است با $C = \frac{۱}{۲} I_۲$. توضیح دهید چرا تحلیل مؤلفه‌های اصلی[۲] روی این داده‌ها جهت مفیدی به دست نمی‌دهد.

ب) (۸.۵ نمره) اکنون نگاشت ویژگی[۳] زیر را در نظر بگیرید:

$$\phi(u, v) = (u^۲, \sqrt{۲}uv, v^۲)^\top.$$

توضیح دهید این نگاشت کدام تفاوت میان داده‌ها را از بین می‌برد و مقدار ϕ را برای هر چهار بردار محاسبه کنید. نشان دهید کرنل زیر معادل نگاشت بالاست و با استفاده از رابطه‌ی زیر ماتریس کرنل K را با درایه‌های $K_{ij} = k(x_i, x_j)$ تشکیل دهید:

$$k(x, z) := (x^\top z)^۲.$$

سپس ماتریس کرنل مرکزی شده زیر را تشکیل دهید:

$$K_c = HKH, \quad H = I_۴ - \frac{۱}{۴}۱۱^\top,$$

که در آن $۱ = (۱, ۱, ۱, ۱)^\top$. منظور از مرکز کردن، کم کردن میانگین داده‌ها از هر داده است، به طوری که میانگین کل صفر شود.
مقدار ویژهٔ غیرصفر K_c و یک بردار ویژهٔ یکه متناظر با آن را تعیین کنید. توضیح دهید چگونه این بردار علامت‌های این چهار بردار را از هم جدا می‌کنند.

پ) (۶ نمره) برای یک اندازه‌گیری جدید $z = (a, b)$، امتیاز Kernel PCA را به صورت زیر نسبت می‌دهیم:

$$s(z) = \frac{۱}{\sqrt{\lambda}} \alpha^\top \tilde{k}(z),$$

که در آن α همان بردار ویژهٔ یکه بخش (ب) با مقدار ویژهٔ $\lambda > ۰$ است و $\tilde{k}(z)$ بردار شباهت z به چهار اندازه‌گیری است که به همان روش مرسوم مرکزی شده است. نشان دهید:

$$s(z) = \frac{a^۲ - b^۲}{\sqrt{۲}}.$$

سپس توضیح دهید چگونه می‌توان با استفاده از روش به دست آمده جهت گوشی را از خروجی به دست آورد و علامت و اندازه این عدد را تفسیر کنید (به جز علامت کلی یک مؤلفه اصلی).

---
[۱] Screen Orientation
[۲] Principal Component Analysis (PCA)
[۳] Feature Mapping

۲ طراحی سامانه‌ی طبقه‌بندی موضوع خبر - ۳۳ نمره

یک خبرگزاری مجموعه‌ای شامل ۱۲۰ هزار خبر انگلیسی در اختیار دارد. هر خبر شامل عنوان و متن بوده و دقیقاً متعلق به یکی از سه موضوع سیاسی، اقتصادی یا ورزشی است. توزیع این موضوعات به‌ترتیب ۷۰، ۲۰ و ۱۰ درصد است. طول خبرها بین ۱۰ تا ۵۰۰ توکن متغیر است و متن‌ها شامل واژه‌های چندمعنا، نام‌های جدید و کلمات نادر[۴] هستند.
خبرگزاری می‌خواهد سامانه‌ای برای طبقه‌بندی موضوع خبر طراحی کند. تیم فنی ابتدا یک خط پایه آماری[۵] می‌سازد و سپس مدل‌های دنباله‌ای و ترنسفورمری را بررسی می‌کند تا در پایان، بهترین مدل را با توجه به کیفیت و محدودیت‌های اجرایی انتخاب کند.

مرحله ۱: ساخت خط پایه آماری (۴.۵ نمره)

تیم فنی برای بررسی اولیه، پس از پیش‌پردازش چهار خبر زیر را انتخاب کرده است:

$$D_1 : \texttt{bank raises interest rate},$$
$$D_2 : \texttt{river bank causes flood},$$
$$D_3 : \texttt{central bank lowers rate},$$
$$D_4 : \texttt{interest rate affects economy}.$$

با فرض استفاده از فراوانی خام برای TF و رابطه زیر:

$$\mathrm{IDF}(t) = \ln\left(\frac{N}{df(t)}\right),$$

فضای سه‌بعدی زیر را برای محاسبات در نظر بگیرید:

$$[\texttt{bank}, \texttt{interest}, \texttt{rate}]$$

پاسخ‌ها را بر حسب a و b بیان کنید:

$$a = \ln ۲, \qquad b = \ln ۳.$$

الف) (۱ نمره) فراوانی سندی[۶] و IDF هر واژه را محاسبه کنید.
ب) (۱ نمره) بردارهای TF–IDF اسناد $D_۱$، $D_۲$ و $D_۴$ را بنویسید.
ج) (۰.۵ نمره) شباهت کسینوسی $D_۱$ با $D_۲$ و $D_۱$ با $D_۴$ را محاسبه کنید.
د) (۲ نمره) نتیجه‌ی بررسی مشابهت را تفسیر کنید.

مرحله ۲: کشف محدودیت خط پایه (۴ نمره)

نتیجه مرحله قبل نشان می‌دهد که اشتراک واژه‌ای همیشه به معنای شباهت معنایی نیست. در $D_۱$، واژه bank به معنای بانک مالی و در $D_۲$ به معنای کناره رودخانه است.
الف) (۰.۵ نمره) تحلیل کنید که TF–IDF چگونه با این واژه برخورد می‌کند.
ب) (۰.۵ نمره) تحلیل کنید که Word2Vec چگونه با این واژه برخورد می‌کند.
ج) (۰.۵ نمره) تحلیل کنید که FastText چگونه با این واژه و کلمات نادر برخورد می‌کند.
د) (۲.۵ نمره) برای سامانه‌ای که باید هم‌زمان واژه‌های چندمعنا، کلمات نادر و کلمات خارج از واژگان[۷] را پردازش کند، یک بازنمایی یا ترکیب مناسب از بازنمایی‌ها پیشنهاد دهید.

مرحله ۳: چالش خبرهای بلند (۱۲ نمره)

تیم فنی برای استفاده از ترتیب و بافت کلمات، مدل‌های دنباله‌ای را نیز بررسی می‌کند. با توجه به اینکه طول بعضی خبرها به ۵۰۰ توکن می‌رسد، ابتدا باید رفتار گرادیان در این مدل‌ها بررسی شود. یک RNN خطی ساده به‌شکل زیر در نظر بگیرید:

$$h_t = w h_{t-۱} + x_t, \qquad y = h_{۱۲}$$

الف) (۲ نمره) مقدار $\frac{\partial y}{\partial h_۰}$ را برای $w = ۰.۶$ محاسبه و رفتار گرادیان را تفسیر کنید.
ب) (۲ نمره) مقدار $\frac{\partial y}{\partial h_۰}$ را برای $w = ۱.۱۵$ محاسبه و رفتار گرادیان را تفسیر کنید.
ج) (۶ نمره) فرض کنید در مسیر حالت سلولی[۸] یک LSTM، مقدار دریچه فراموشی[۹] در تمام ۱۲ گام برابر $f_t = ۰.۹۵$ باشد؛ مقدار $\frac{\partial C_{۱۲}}{\partial C_۰}$ را محاسبه کنید.
د) (۲ نمره) توضیح دهید این نتیجه چه ارتباطی با پردازش خبرهای بلند و وابستگی‌های طولانی[۱۰] دارد.

---

[۴] Rare Words
[۵] Baseline
[۶] Document Frequency
[۷] Out-of-Vocabulary (OOV)
[۸] Cell State
[۹] Forget Gate
[۱۰] Long-range Dependencies

مرحله ۴: بررسی رقیب ترنسفورمری (۷ نمره)

مدل‌های بازگشتی، هرچند مشکل گرادیان را تا حدی حل می‌کنند، همچنان پردازشی ماهیتاً ترتیبی دارند. تیم فنی برای مقایسه، یک Transformer Encoder سبک را بررسی می‌کند که می‌تواند ارتباط مستقیم میان کلمات خبر را مدل‌سازی کند. در یکی از لایه‌های توجه به خود[۱۱] کدگذار، ماتریس‌های پرس‌وجو[۱۲]، کلید[۱۳] و مقدار[۱۴] برای سه توکن یک خبر به‌شکل زیر هستند:

$$Q = \begin{bmatrix} ۱ & ۰ \\ ۱ & ۱ \\ ۰ & ۱ \end{bmatrix}, \qquad K = \begin{bmatrix} ۱ & ۰ \\ ۱ & ۱ \\ ۰ & ۱ \end{bmatrix}, \qquad V = \begin{bmatrix} ۱ & ۰ \\ ۰ & ۲ \\ ۲ & ۱ \end{bmatrix}.$$

با توجه به $d_k = ۲$، خروجی زیر را محاسبه کنید:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\intercal}{\sqrt{d_k}}\right) V$$

در این دنباله کوچک توکن <PAD> وجود ندارد. برای ساده‌شدن محاسبات می‌توانید از تقریب‌های زیر استفاده کنید:

$$e^{۱/\sqrt{۲}} \approx ۲, \qquad e^{\sqrt{۲}} \approx ۴$$

الف) (۲ نمره) ماتریس $QK^\intercal$ و امتیازهای مقیاس‌شده $\frac{QK^\intercal}{\sqrt{d_k}}$ را محاسبه کنید.
ب) (۱ نمره) وزن‌های سافتمکس سطری را محاسبه کنید.
ج) (۳ نمره) خروجی نهایی $\text{Attention}(Q, K, V)$ را بنویسید.
د) (۱ نمره) در یک جمله توضیح دهید چرا در این Encoder از ماسک علّی[۱۵] استفاده نشده است.

مرحله ۵: طراحی طبقه‌بند ترنسفورمری (۵.۵ نمره)

اکنون مسیر کامل طبقه‌بندی تک‌برچسبی سه موضوع خبری را با یک Transformer Encoder طراحی کنید.
الف) (۰ نمره) مشخص کنید داده چگونه به بخش‌های آموزش، اعتبارسنجی و آزمون تقسیم می‌شود و واژگان یا توکن‌ساز بر اساس کدام بخش داده آماده می‌شود تا از نشت اطلاعات[۱۶] جلوگیری شود.
ب) (۱.۵ نمره) توضیح دهید توکن‌سازی زیرواژه‌ای[۱۷] چه کمکی به نام‌ها و کلمات نادر می‌کند.
ج) (۲.۵ نمره) مشخص کنید ماسک پدینگ[۱۸] و کدگذاری جایگاهی[۱۹] در کجا به کار می‌روند و خروجی توکن‌ها چگونه به یک بردار خبر تبدیل می‌شود.
د) (۱ نمره) لایه نهایی و تابع زیان را مشخص کنید.
ه) (۰.۵ نمره) با توجه به توزیع نامتوازن کلاس‌ها، توضیح دهید مدل چگونه آموزش و ارزیابی می‌شود.

---

[۱۱] Self-Attention
[۱۲] Query
[۱۳] Key
[۱۴] Value
[۱۵] Causal Mask
[۱۶] Information Leakage
[۱۷] Subword Tokenization
[۱۸] Padding Mask
[۱۹] Positional Encoding

۳ تشخیص اجزای کلام با مدل زبانی GPT - ۲۹ نمره

تشخیص اجزای کلام[۲۰]، یعنی مسئله‌ای است که در آن قصد داریم کلمات یک جمله را بر اساس نقش دستوری آن‌ها (مثلاً فعل، فاعل، مفعول، قید، حرف اضافه، حرف ربط و ...) دسته‌بندی کنیم.
فرض کنید یک مجموعه داده آماده با حجم زیاد در اختیار داریم. قصد داریم برای این کار از مدل GPT که از قبل آموزش دیده است استفاده کنیم. به‌عنوان مثال، به‌ازای هر جمله، دنباله‌ای از برچسب‌های متناظر با آن مشخص شده است:
جمله: «دانشجو کتاب را خواند» ⟵ برچسب‌ها: [اسم، اسم، نشانهٔ مفعولی، فعل].
نکته: جهت ساده‌سازی مسئله و پرهیز از چالش‌های توکنیزیشن زیرکلمه‌ای[۲۱]، فرض کنید هر توکن دقیقاً معادل یک واژه است.
مدل GPT ذاتاً برای پیش‌بینی توکن بعدی آموزش دیده است:

$$P(x_t \mid x_1, x_2, \dots, x_{t-1})$$

اما هدف ما یک طبقه‌بندی به‌ازای هر توکن است:

$$\hat{y}_t = \arg\max_{c \in C} P(c \mid x_t, \text{context})$$

منظور از context، همه‌ی توکن‌های دیگر در ورودی است. در این رابطه، C مجموعهٔ برچسب‌های اجزای کلام است.

الف) (۵.۵ نمره) فرض کنید یک مدل GPT آموزش‌دیده روی یک مخزن بزرگ از اسناد خام و با هدف پیش‌بینی توکن بعدی[۲۲] در اختیار داریم. چگونه و با چه تغییراتی می‌توان از این مدل پایه استفاده کرد و یک مدل برای تشخیص اجزای کلام ساخت؟ در نظر بگیرید که زیرساخت پردازشی خیلی قوی در اختیار نیست و همین‌طور مجموعه‌دادهٔ برچسب‌دار محدودی هم برای تسک تشخیص اجزای کلام در اختیار داریم.

ب) (۵ نمره) آیا استفاده از یک مدل صرفاً دیکودری مانند GPT برای وظیفهٔ تشخیص اجزای کلام ایدهٔ خوبی است، یا انتخاب بهتری وجود دارد؟ دلیل خود را شرح دهید.

ج) (۴ نمره) فرض کنید زیرساخت بیشتری در اختیار ما قرار گرفت و تصمیم گرفتیم قدرت مدل را افزایش دهیم. برای این منظور از تنظیم دقیق تمام مدل پایه[۲۳] استفاده می‌کنیم. پس از صرف هزینهٔ زیاد مشاهده کردیم:

- خطای آموزشی به سرعت به صفر میل می‌کند.
- دقت روی داده‌های آموزشی تقریباً ایده‌آل است.
- اما خطای داده‌های تست بیشتر و بیشتر می‌شود.

علت عدم تعمیم‌پذیری را شرح دهید.

د) (۷ نمره) چگونه می‌توان مشکل مطرح‌شده در بند قبل (عدم تعمیم‌پذیری مدل) را با راه‌حلی مؤثرتر از محدود کردن تغییر وزن‌ها به چند لایه‌ی آخر مدل برطرف کرد؟ راهکار خود را به‌صورت دقیق معرفی کنید و سازوکار آن را شرح دهید.

هـ) (۳.۵ نمره) دقت مدل ما به ۹۵٪ رسیده است. اما می‌خواهیم دقت را از این بالاتر ببریم. برای این کار به داده‌های آموزشی نیاز داریم:

۱. چنین داده‌های برچسب‌داری در اختیار نداریم.

۲. حتی اگر داشتیم، هزینهٔ آموزش بسیار زیاد بود.

ایدهٔ ما این است که از داده‌های بدون برچسب موجود در اینترنت استفاده کنیم. فرآیند پیشنهادی برای صرفه‌جویی در هزینه شرح دهید.
مشکل اصلی: نمی‌توانیم بفهمیم کدام داده «مفید» است یا خیر، چون برچسب‌ها را نداریم و نمی‌توانیم خروجی مدل را با آن‌ها مقایسه کنیم.
راه‌حلی ارائه دهید که بتواند بدون آموزش اضافی و بدون تغییر معماری، مفید بودن داده‌ها را تخمین بزند.

و) (۲ نمره) در تحلیل تعمیم‌پذیری مدل‌های یادگیری ماشین، دو نوع عدم قطعیت وجود دارد:

- **عدم قطعیت ذاتی**[۲۴]: میزان ابهام ذاتی داده‌ها را نشان می‌دهد. مثلاً ممکن است برای یک کلمه، برچسب یکتایی وجود نداشته باشد. این خطا قابل کاهش نیست و خطای بیز نامیده می‌شود.
- **عدم قطعیت مدل / شناختی**[۲۵]: میزان ضعف مدل در یادگیری را می‌سنجد. این خطا با داده بیشتر یا مدل بهتر قابل کاهش است و خطای تخمین نامیده می‌شود.

سؤال: معیار Perplexity یک مدل زبانی را در نظر بگیرید که برای امتیازدهی به جمله‌ها استفاده می‌شود. این معیار کدام‌یک از این دو عدم قطعیت را می‌سنجد؟ یا ترکیبی از آن‌هاست، یا مفهوم دیگری است؟

ز) (۲ نمره) روشی طراحی کنید که بتواند عدم قطعیت شناختی را مستقل از عدم قطعیت ذاتی بسنجد، به‌گونه‌ای که مدل بتواند نقاط ضعف خود را شناسایی کرده و بهبود دهد.

---
[۲۰] Part-of-Speech Tagging
[۲۱] Subword Tokenization (BPE)
[۲۲] Next Token Prediction
[۲۳] Full Fine-tune
[۲۴] Aleatoric Uncertainty
[۲۵] Epistemic Uncertainty

۴ از GAN شرطی تا DDPM - ۳۷ نمره

هدف این سؤال، بررسی و حل سه خانواده مدل مولد شرطی و احتمالاتی، یعنی GAN شرطی، VAE شرطی و DDPM، و تحلیل تابع هدف و ساختار هر یک است.

مقدمات و روابط پیش‌نیاز

در GAN[۲۶] پایه دو شبکه وجود دارد: مولد[۲۷] $G_\theta(z)$ که نویز $z \sim p(Z)$ را به نمونه‌ی $\hat{x}$ تبدیل می‌کند، و متمایزکننده[۲۸] $D_\phi(x)$ که احتمال واقعی بودن نمونه‌ی x را در بازه‌ی $[۰, ۱]$ برمی‌گرداند. این دو شبکه در یک بازی مینیمکس آموزش می‌بینند:

$$\min_G \max_D \; \mathbb{E}_{x\sim p_{data}}[\log D(x)] + \mathbb{E}_{z\sim p(Z)}[\log(۱ - D(G(z)))].$$

برای متمایزکننده‌ی بهینه داریم $D^*(x) = \frac{p_{data}(x)}{p_{data}(x)+p_g(x)}$، و در تعادل $p_g = p_{data}$. برای شرطی‌سازی GAN، یکی از روش‌ها آن است که برچسب c هم به مولد و هم به متمایزکننده داده شود: $G_\theta(z, c)$ و $D_\phi(x, c)$. تابع هدف این حالت چنین است:

$$\min_G \max_D \; \mathbb{E}_{x,c\sim p_{data}}[\log D(x, c)] + \mathbb{E}_{z\sim p(Z),\, c\sim p(C)}[\log(۱ - D(G(z, c), c))].$$

روش دیگر برای شرطی‌سازی، AC-GAN است که در آن متمایزکننده دو سر خروجی دارد: یکی $D_{adv}(x) \in [۰, ۱]$ برای تشخیص واقعی/جعلی و دیگری $D_{class}(c|x) \in \mathbb{R}^C$ برای طبقه‌بندی کلاس. در این ساختار، متمایزکننده D تابع هزینه[۲۹] $L_D = L^D_{adv} + \lambda L^D_{class}$ را کمینه می‌کند و مولد G تابع هزینه $L_G = L^G_{adv} + \lambda L^G_{class}$ را کمینه می‌کند، که در آن λ یک ابرپارامتر قابل تنظیم برای وزن‌دهی به جمله‌ی طبقه‌بندی است.
در VAE[۳۰] پایه، داده‌ها با یک مدل نهان[۳۱] مدل می‌شوند: $z \sim p(z) = \mathcal{N}(۰, I)$ و $x \sim p_\theta(x|z)$. چون محاسبه‌ی $p_\theta(x) = \int p_\theta(x|z)p(z)\,dz$ غیرممکن است، توزیع تقریبی $q_\phi(z|x)$ معرفی می‌شود و کران پایین شواهد (ELBO) بیشینه می‌شود:

$$\mathcal{L}(\theta, \phi; x) = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - \mathrm{KL}(q_\phi(z|x)\|p(z)).$$

برای اینکه بتوان از $q_\phi(z|x)$ گرادیان گرفت، از ترفند بازپارامتری‌سازی استفاده می‌شود: اگر $z \sim \mathcal{N}(\mu, \sigma^۲)$ باشد، آن را به‌صورت

$$z = \mu + \sigma \odot \varepsilon, \qquad \varepsilon \sim \mathcal{N}(۰, I)$$

می‌نویسیم.
در سراسر مسئله از واگرایی KL[۳۲] استفاده می‌شود که به‌صورت

$$\mathrm{KL}(p\|q) = \int p(x) \log \frac{p(x)}{q(x)}\, dx$$

تعریف می‌شود و همیشه $\mathrm{KL}(p\|q) \geq ۰$ است؛ تساوی فقط وقتی برقرار است که $p = q$ باشد. دو حالت خاص گاوسی آن کاربرد فراوانی دارند. اگر دو گاوسی هم‌واریانس باشند،

$$\mathrm{KL}(\mathcal{N}(\mu_۱, \sigma^۲) \,\|\, \mathcal{N}(\mu_۲, \sigma^۲)) = \frac{(\mu_۱ - \mu_۲)^۲}{۲\sigma^۲},$$

و در حالت کلی

$$\mathrm{KL}(\mathcal{N}(\mu_۱, \sigma_۱^۲) \,\|\, \mathcal{N}(\mu_۲, \sigma_۲^۲)) = \log \frac{\sigma_۲}{\sigma_۱} + \frac{\sigma_۱^۲ + (\mu_۱ - \mu_۲)^۲}{۲\sigma_۲^۲} - \frac{۱}{۲}.$$

به‌ویژه، KL بین $q_\phi(z|x) = \mathcal{N}(\mu, \sigma^۲)$ و پیشین $\mathcal{N}(۰, I)$ برابر است با

$$\mathrm{KL}(q_\phi(z|x) \,\|\, \mathcal{N}(۰, I)) = -\frac{۱}{۲} \sum_j \left(۱ + \log \sigma_j^۲ - \mu_j^۲ - \sigma_j^۲\right).$$

با این مقدمات، صورت مسئله در سه بخش اول، دوم و سوم ارائه می‌شود که به‌ترتیب به GAN شرطی، VAE شرطی و DDPM[۳۳] می‌پردازند.

بخش اول: مدل‌های مولد شرطی (AC-GAN) (۱۲.۵ نمره)

در این بخش، ساختاری برای تولید تصاویر مشروط به برچسب با استفاده از GAN پیشنهاد شده است. در این ساختار، مولد $G_\theta(z, c)$ از نویز z و برچسب نمونه‌گیری‌شدهٔ c تصویری مشروط به c می‌سازد. متمایزکننده D_ϕ فقط تصویر x را می‌گیرد و دو خروجی دارد: $D_{adv}(x)$ احتمال واقعی‌بودن تصویر، و $D_{class}(\cdot|x)$ توزیع احتمال روی C کلاس. تعاریف زیر را در نظر بگیرید:

$$c \sim p(C), \quad z \sim p(Z), \quad x \sim p_{data}(X|c),$$

---
[۲۶] Generative Adversarial Network
[۲۷] Generator
[۲۸] Discriminator
[۲۹] Loss (Cost)
[۳۰] Variational Autoencoder
[۳۱] Latent Variable Model
[۳۲] Kullback–Leibler divergence
[۳۳] Denoising Diffusion Probabilistic Models

$$G_\theta(z,c), \quad D_\phi,$$
$$D_{adv}(x) \in [۰,۱], \quad D_{class}(c|x) \in \mathbb{R}^C.$$

توابع هزینه:

$$L^D_{adv} = -\mathbb{E}_{x\sim p_{data}(X|c),\, c\sim p(C)}[\log D_{adv}(x)] - \mathbb{E}_{z\sim p(Z),\, c\sim p(C)}[\log(۱ - D_{adv}(G(z,c)))]$$

$$L^G_{adv} = -\mathbb{E}_{z\sim p(Z),\, c\sim p(C)}[\log D_{adv}(G(z,c))]$$

$$L^D_{class} = -\mathbb{E}_{x\sim p_{data}(X|c),\, c\sim p(C)}[\log D_{class}(c|x)]$$

$$L^G_{class} = -\mathbb{E}_{z\sim p(Z),\, c\sim p(C)}[\log D_{class}(c|G(z,c))]$$

در آموزش، متمایزکننده D تابع هزینه‌ی

$$L_D = L^D_{adv} + \lambda L^D_{class}$$

را کمینه می‌کند و مولد G تابع هزینه‌ی

$$L_G = L^G_{adv} + \lambda L^G_{class}$$

را کمینه می‌کند. در این‌جا λ ابرپارامتری است که اهمیت جمله‌ی طبقه‌بندی را نسبت به جمله‌ی تخاصمی تنظیم می‌کند.

الف) (۶.۵ نمره) فرض کنید مدل فوق آموزش داده شده و به تعادل رسیده است. شبکه‌ی G چه توزیعی از داده را توانسته است یاد بگیرد؟ پاسخ خود را با استدلال مشخص کنید.

ب) (۶ نمره) نقش هر کدام از چهار عبارت هزینه‌ی فوق در آموزش ساختار چیست؟ حذف هر کدام چه تأثیری بر نتیجه دارد؟

بخش دوم: VAE برای تولید شرطی (CVAE) (۹ نمره)

می‌خواهیم برای همان مسئله‌ی تولید تصویر مشروط به برچسب c از معماری VAE استفاده کنیم. منظور، **CVAE** استاندارد است. فرض کنید:

- c به‌صورت one-hot وارد شبکه می‌شود.
- پیشین $p(z|c) = \mathcal{N}(۰, I)$ و مستقل از c است.

ج) (۴ نمره) اجزای اصلی شبکه را نام ببرید و برای هر جزء، ورودی‌ها و خروجی‌ها را مشخص کنید.

د) (۲.۵ نمره) تابع هدف (ELBO) را برای CVAE بنویسید.

هـ) (۲.۵ نمره) توضیح دهید در مرحله‌ی تولید، کدام اجزا استفاده می‌شوند و کدام کنار می‌روند.

بخش سوم: مدل‌های پخش احتمالی واسازنده (DDPM) (۱۵.۵ نمره)

در مدل DDPM، فرآیند پیش‌رو داده را طی T گام به نویز گاوسی تبدیل می‌کند. در هر گام، نویز کمی اضافه می‌شود:

$$q(x_t|x_{t-۱}) = \mathcal{N}(x_t; \sqrt{۱-\beta_t}\, x_{t-۱}, \beta_t I)$$

که در آن:

$$\alpha_t = ۱ - \beta_t, \qquad \bar{\alpha}_t = \prod_{s=۱}^{t} \alpha_s$$

و پارامترهای β_t ثابت و از پیش تعیین‌شده هستند (یادگرفتنی نیستند).
که داریم:

$$q(x_t|x_۰) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}\, x_۰, (۱-\bar{\alpha}_t)I).$$

و توزیع $q(x_{t-۱}|x_t, x_۰)$ که برای به دست آوردن مدل معکوس مورد استفاده قرار می‌گیرد به صورت در می‌آید:

$$q(x_{t-۱}|x_t, x_۰) = \mathcal{N}(x_{t-۱}; \tilde{\mu}_t(x_t, x_۰), \tilde{\beta}_t I)$$

که:

$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-۱}}\,\beta_t}{۱-\bar{\alpha}_t}\, x_۰ + \frac{\sqrt{\alpha_t}\,(۱-\bar{\alpha}_{t-۱})}{۱-\bar{\alpha}_t}\, x_t$$

$$\tilde{\beta}_t = \frac{۱-\bar{\alpha}_{t-۱}}{۱-\bar{\alpha}_t}\,\beta_t$$

مدل معکوس را به‌صورت زیر پارامتردهی می‌کنیم:

$$p_\theta(x_{t-۱}|x_t) = \mathcal{N}(x_{t-۱}; \mu_\theta(x_t, t), \sigma_t^۲ I)$$

فرض مهم: واریانس مدل با واریانس پسین برابر است:

$$\sigma_t^۲ = \tilde{\beta}_t$$

تابع هدف ساده‌شده‌ی DDPM برابر است با:

$$L_{simple} = \mathbb{E}_{t,x_0,\varepsilon}\left[\left\|\varepsilon - \varepsilon_\theta\left(\sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\,\varepsilon,\, t\right)\right\|^2\right], \quad \varepsilon \sim \mathcal{N}(0, I).$$

و) (۷ نمره) نشان دهید رابطه‌ی زیر برای میانگین توزیع $q(x_{t-1}|x_t, x_0)$ برقرار است و پیش‌بینی میانگین این توزیع معادل پیش‌بینی نویز است:

$$\tilde{\mu}_t(x_t, \varepsilon) = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\,\varepsilon\right)$$

ز) (۸.۵ نمره) از این نتیجه استنتاج کنید که با پارامتردهی مدل به‌صورت زیر:

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\,\varepsilon_\theta(x_t, t)\right)$$

می‌توان نشان داد که کمینه‌سازی

$$\mathrm{KL}(q(x_{t-1}|x_t, x_0)\,\|\,p_\theta(x_{t-1}|x_t))$$

معادل کمینه‌سازی L_{simple} است. (راهنما: از فرض برابر بودن واریانس‌ها و رابطه‌ی KL گاوسی هم‌واریانس استفاده کنید.)