به نام خداوند بخشنده مهربان

المپیاد هوش مصنوعی

باشگاه دانش‌پژوهان جوان

تابستان ۱۴۰۵

آزمون نظری

مدت زمان: ۱۸۰ دقیقه

سوال ۱ (۲۰ نمره)

این پرسش بر اساس اشتباه رایجی طراحی شده است که در آزمون عملی پایان دورهٔ گذشته، شمار قابل توجهی از دانش‌پژوهان با آن مواجه شدند. مدل رگرسیون خطی با عرض از مبدأ را به صورت زیر در نظر بگیرید.

$$\hat{y} = X\beta$$

فرض کنید ماتریس طراحی X شامل یک ستون برای عرض از مبدأ است. تابع هزینه به صورت میانگین مربعات خطا تعریف می‌شود:

$$J(\beta) = \frac{1}{n}\|X\beta - y\|^2$$

الگوریتم کاهش گرادیان با نرخ یادگیری η و مقدار اولیه $\beta_0 = 0$ به صورت زیر است:

$$\beta_{t+1} = \beta_t - \eta \nabla J(\beta_t)$$

یک مجموعه دادهٔ کوچک با $n = 4$ شامل ویژگی x و متغیر هدف y به صورت زیر داده شده است:

$$x = \begin{bmatrix} 0.5 \\ -0.5 \\ 0.5 \\ -0.5 \end{bmatrix}, \quad y = \begin{bmatrix} 6 \\ 4 \\ 6 \\ 4 \end{bmatrix}$$

و ماتریس طراحی:

$$X = \begin{bmatrix} 1 & 0.5 \\ 1 & -0.5 \\ 1 & 0.5 \\ 1 & -0.5 \end{bmatrix}$$

فرض کنید بردار ضرایب اولیه نیز صفر است:

$$\beta_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

(الف) (۲ نمره) با استفاده از تعریف

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}, \quad SS_{res} = \sum_i (y_i - \hat{y}_i)^2, \quad SS_{tot} = \sum_i (y_i - \bar{y})^2$$

نشان دهید برای مدل مبنایی که برای همه نمونه‌ها مقدار ثابت $\bar{y}$ را پیش‌بینی می‌کند، $R^2 = 0$ برقرار است. سپس توضیح دهید که $R^2 < 0$ چه معنایی دارد و چرا عملکردی ضعیف‌تر از پیش‌بینی با میانگین تلقی می‌شود.

(ب) (۳ نمره) مقدار بردار ضرایب متناظر با جواب بهینه $\beta^* = (X^T X)^{-1} X^T y$ را به دست آورید.

(ج) (۵ نمره) با استفاده از روابط بازگشتی کاهش گرادیان، رابطهٔ صریح برای $\beta_t = [a_t, b_t]^T$ را به دست آورید. (راهنمایی: $\beta_t - \beta^*$ را به صورت بازگشتی محاسبه کنید.)

(د) (۴ نمره) فرض کنید $\eta = 10^{-6}$ (نرخ یادگیری بسیار کوچک). با استفاده از تقریب $(1+u)^n \approx 1 + nu$ برای $|u| \ll 1$، مقدار β_{1000} را محاسبه کنید. سپس R^2 را به دست آورید و نشان دهید در این حالت $R^2 < 0$ می‌شود.

(ه) (۳ نمره) فرض کنید $\eta = 10$ (نرخ یادگیری بسیار بزرگ). نشان دهید الگوریتم واگرا خواهد شد. همچنین نشان دهید پس از ۱۰۰۰ مرحله R^2 به شدت منفی خواهد شد. (نیازی به محاسبهٔ دقیق R^2 نیست.)

(و) (۳ نمره) بازه‌ای معتبر برای نرخ یادگیری η تعیین کنید که در آن الگوریتم پایدار بوده و β_t به β^* همگرا شود.

سوال ۲ (۱۷ نمره)

مجموعه داده زیر شامل ۳ نقطه است:

$$D = \{(۰, +), (-۱, -), (+۱, -)\}$$

(الف) (۳ نمره) نگاشت ویژگی $\phi(x) = \begin{bmatrix} ۱ \\ \sqrt{۲}x \\ x^۲ \end{bmatrix}$ را در نظر بگیرید. آیا داده‌ها در این فضای ویژگی جدید به‌صورت خطی تفکیک‌پذیرند؟ دلیل خود را توضیح دهید.

(ب) (۹ نمره) هدف، جداسازی دو کلاس داده‌های D با یک ابرصفحه است، به‌گونه‌ای که حاشیه بیشینه شود و حاشیه از کلاس منفی دو برابر حاشیه از کلاس مثبت باشد. بردار وزن ویژگی‌ها را $w = (w_۱, w_۲, w_۳)^T$ و عرض از مبدأ را b، در نظر بگیرید. مسئلهٔ بهینه‌سازی متناظر را بنویسید و تا حد امکان ساده کنید. (راهنمایی: فاصله نقطه x از ابرصفحه $w^Tx + b = ۰$ برابر است با $\frac{|w^Tx+b|}{\|w\|}$.)

(ج) (۵ نمره) با استفاده از ضرایب لاگرانژ، مسئله را حل کنید. ضرایب صفحه جداکننده w و b، و سپس مقدار حاشیه از کلاس مثبت را مشخص کنید.

سوال ۳ (۱۶ نمره)

یک مدل شبکهٔ عصبی برای دسته‌بندی دوتایی در نظر بگیرید که در آن برچسب $y \in \{۰, ۱\}$ و ورودی $x \in \mathbb{R}^p$ است. این شبکه یک لایه پنهان با تابع فعال‌سازی سیگموئید دارد و در لایه خروجی، برای تولید احتمال تعلق به کلاس ۱، تابع سیگموئید (لجستیک) روی ترکیب خطی واحدهای پنهان اعمال می‌شود؛ معیار آموزش نیز زیان آنتروپی متقاطع (log loss) است. ساختار این مدل به صورت زیر تعریف شده است:

$$Z_m = \sigma(\alpha_{۰,m} + \alpha_m^T x), \quad m = ۱, \dots, M, \quad \alpha_m \in \mathbb{R}^p, \quad \alpha_{۰,m} \in \mathbb{R}$$

$$A(x) = \beta_۰ + \beta^T Z, \quad Z = (Z_۱, \dots, Z_M)^T \in \mathbb{R}^M \quad \beta \in \mathbb{R}^M \quad \beta_۰ \in \mathbb{R}$$

$$f(x) = P(Y = ۱ \mid x) = \sigma(A(x))$$

تابع سیگموئید $\sigma(a) = \frac{۱}{۱+e^{-a}}$ و زیان نمونهٔ (x, y) به صورت زیر است:

$$\ell(f(x), y) = -\Big[y \log f(x) + (۱ - y) \log (۱ - f(x)) \Big]$$

یادآوری: رگرسیون لجستیک روی ورودی x مدلی به صورت $P(Y = ۱ \mid x) = \sigma(w_۰ + w^T x)$ است.

(الف) (۱۰ نمره) فرض کنید وزن‌های لایهٔ اول (یعنی $\alpha_{۰,m}$ و α_m) مقادیر بسیار نزدیک به صفر دارند. با استفاده از بسط تیلور مرتبهٔ اول تابع سیگموئیدِ لایه پنهان حول نقطهٔ صفر، نشان دهید تحت این فرض، خروجی شبکه تقریباً همان **رگرسیون لجستیک** روی ورودی x است؛ یعنی

$$f(x) \approx \sigma(w_۰ + w^T x)$$

و ضرایب $w_۰$ و w را بر حسب پارامترهای اصلی مدل (α، β) مشخص کنید.

(ب) (۶ نمره) توضیح دهید این تقلیل به رگرسیون لجستیک چه پیامدی برای ظرفیت یادگیری شبکه در ناحیهٔ وزن‌های کوچک دارد (به‌ویژه از نظر شکل مرز تصمیم و رفتار واحدهای پنهان). چرا برای شکستن این تقارن و بهره‌مندی از توانایی شبکه در یادگیری مرزهای تصمیم غیرخطی، به مقداردهی اولیهٔ وزن‌ها با اعداد تصادفی غیرصفر با واریانس مناسب (مانند مقداردهی اولیهٔ (Xavier/Glorot) نیاز داریم؟ همچنین توضیح دهید چرا وزن‌های اولیهٔ صرفاً بزرگ نیز راه‌حل مناسبی نیستند.

راهنمایی: برای تحلیل رفتار شبکه در ناحیه وزن‌های کوچک، تقریب بسط تیلور تابع $f(x)$ تا مرتبه دوم به صورت زیر مفید است:

$$f(x) \approx f(۰) + f'(۰)x + \frac{۱}{۲} f''(۰)x^۲$$

سوال ۴ (۲۸ نمره)

در بسیاری از مسائل دنیای واقعی، داده‌ها از چندین منبع یا «دیدگاه» مختلف جمع‌آوری می‌شوند؛ برای مثال، یک ویدیو شامل هم سیگنال تصویر است و هم سیگنال صدا، یا در بیوانفورماتیک، ممکن است برای یک سلول هم داده‌های بیان ژن داشته باشیم و هم داده‌های پروفایل پروتئینی. تحلیل مؤلفه‌های اصلی (PCA) به ما کمک می‌کند تا ساختار واریانس را در یک مجموعه داده پیدا کنیم، اما وقتی می‌خواهیم بدانیم **چگونه دو مجموعه داده متفاوت با یکدیگر ارتباط دارند** و مشترکات آن‌ها چیست، به ابزاری قوی‌تر نیاز داریم. اینجاست که **تحلیل همبستگی کانونی (CCA)** وارد میدان می‌شود. CCA به دنبال یافتن جهت‌هایی در دو فضای ویژگی است که همبستگی بین تصویرهای فرافکنی‌شده (Projections) از دو مجموعه داده را بیشینه کند.

در این مسئله، ما گام‌به‌گام از طریق فرمول‌بندی بهینه‌سازی، هندسه فضاهای داخلی و جبر ماتریسی (تجزیه مقدار منفرد)، نه تنها الگوریتم CCA را استخراج می‌کنیم، بلکه نشان می‌دهیم که چگونه این مفهوم به طور عمیقی با PCA و تقریب‌های رتبه‌پایین گره خورده است.

فرض کنید

$$X \in \mathbb{R}^{n\times p}, \qquad Y \in \mathbb{R}^{n\times q}$$

دو ماتریس داده با ستون‌های میانگین‌مرکزشده باشند. ماتریس‌های کوواریانس و کوواریانس متقابل را به صورت زیر تعریف می‌کنیم:

$$\Sigma_{xx} = X^T X, \qquad \Sigma_{yy} = Y^T Y, \qquad \Sigma_{xy} = X^T Y.$$

توجه کنید Σ_{xx} و Σ_{yy} مثبت نیمه‌معین و در نتیجه وارون‌پذیرند.

قسمت اول: فرمول‌بندی هدف و استخراج شرایط ایستایی

اکنون می‌خواهیم شهودِ یافتن بیشترین همبستگی را به زبان ریاضی تبدیل کنیم. برای یافتن جهت‌هایی که بیشترین همبستگی را دارند، مسئله بهینه‌سازی زیر را در نظر بگیرید:

$$\max_{a,b} \quad a^T \Sigma_{xy} b$$

تحت قیدهای نرمال‌سازی:

$$a^T \Sigma_{xx} a = ۱, \qquad b^T \Sigma_{yy} b = ۱.$$

(الف) (۴ نمره) با استفاده از روش ضرایب لاگرانژ و شرایط ایستایی مرتبه اول، نشان دهید هر نقطه ایستا در دستگاه معادلات زیر صدق می‌کند:

$$\Sigma_{xy} b = \lambda_۱ \Sigma_{xx} a, \qquad \Sigma_{yx} a = \lambda_۲ \Sigma_{yy} b.$$

(توجه: در اینجا $\lambda_۱$ و $\lambda_۲$ ضرایب لاگرانژ متناظر با دو قید هستند.)

(ب) (۴ نمره) سپس نشان دهید این دو ضریب لاگرانژ در هر نقطه ایستا با هم یکسان‌اند ($\lambda_۱ = \lambda_۲ = \lambda$) و مقدار مشترک آن‌ها برابر است با مقدار تابع هدف، یعنی $a^T \Sigma_{xy} b$. در نهایت، با جایگذاری و ساده‌سازی، ثابت کنید $\lambda^۲$ یک مقدار ویژه تعمیم‌یافته برای مسئله زیر است:

$$\Sigma_{xy} \Sigma_{yy}^{-۱} \Sigma_{yx} a = \lambda^۲ \Sigma_{xx} a.$$

قسمت دوم: ساده‌سازی هندسی و اتصال به SVD

در این بخش ابتدا تعریف $\Sigma^{۱/۲}$ را بر اساس تجزیهٔ مقدار ویژه مرور می‌کنیم.
تعریف $\Sigma^{۱/۲}$ بر اساس تجزیهٔ مقدار ویژه: برای یک ماتریس متقارن مثبت نیمه‌معین Σ، تجزیهٔ مقدار ویژهٔ آن را به صورت زیر در نظر بگیرید:

$$\Sigma = Q \Lambda Q^T,$$

که در آن Q ماتریسی متعامد ($Q^T Q = I$) و $\Lambda = \mathrm{diag}(\lambda_۱, \dots, \lambda_p)$ ماتریسی قطری شامل مقادیر ویژهٔ مثبت است. آنگاه **ریشهٔ دوم ماتریسی** $\Sigma^{۱/۲}$ به صورت زیر تعریف می‌شوند:

$$\Sigma^{۱/۲} = Q \Lambda^{۱/۲} Q^T$$

که در آن $\Lambda^{۱/۲} = \mathrm{diag}(\sqrt{\lambda_۱}, \dots, \sqrt{\lambda_p})$ و $\Lambda^{-۱/۲} = \mathrm{diag}(۱/\sqrt{\lambda_۱}, \dots, ۱/\sqrt{\lambda_p})$.

اکنون تغییر متغیرهای زیر را تعریف می‌کنیم:

$$u = \Sigma_{xx}^{۱/۲} a, \qquad v = \Sigma_{yy}^{۱/۲} b.$$

(ج) (۵ نمره) نشان دهید مسئله بخش اول با مسئله زیر معادل است:

$$\max_{\|u\|=\|v\|=۱} u^T K v,$$

که در آن ماتریس کوواریانس متقابل K به صورت زیر تعریف می‌شود:

$$K = \Sigma_{xx}^{-۱/۲} \Sigma_{xy} \Sigma_{yy}^{-۱/۲}.$$

سپس با استفاده از تجزیه مقدار منفرد ماتریس K، یعنی $K = UDV^T$، مقدار بهینه تابع هدف و بردارهای a و b متناظر را به دست آورید.
($D = \mathrm{diag}(\sigma_۱, \dots, \sigma_r), \sigma_۱ \geq \sigma_۲ \geq \cdots \geq \sigma_r > ۰$)

قسمت سوم: استخراج اطلاعات، تقریب رتبه‌پایین و تفسیر نهایی

در کاربردهای عملی، ما معمولاً به تمام مؤلفه‌ها نیاز نداریم، بلکه به دنبال k همبستگی قوی هستیم. این ما را به سراغ مفهوم تقریب رتبه‌پایین می‌برد. ماتریس K را مانند بخش قبل در نظر بگیرید و تجزیه مقدار منفرد آن را به صورت زیر بنویسید:

$$K = UDV^T,$$

(د) (۴ نمره) نشان دهید برای هر ماتریس M با $\text{rank}(M) \leq k$، نامساوی زیر (لم اکارت‌ـ یانگ‌ـ میرسکی) برقرار است:

$$\|K - M\|_F^2 \geq \sum_{i=k+1}^{r} \sigma_i^2.$$

(ه) (۴ نمره) اگر داشته باشیم $\sigma_k > \sigma_{k+1}$، نشان دهید جواب یکتای مسئله تقریب رتبه‌پایین به صورت زیر است:

$$M = U_k D_k V_k^T,$$

که $U_k \in \mathbb{R}^{p\times k}$ و $V_k \in \mathbb{R}^{q\times k}$ به ترتیب شامل اولین k ستون ماتریس‌های U و V هستند و $D_k \in \mathbb{R}^{k\times k}$ یک ماتریس قطری است که k مقدار منفرد بزرگ‌تر را در بر دارد، یعنی $D_k = \text{diag}(\sigma_1, \dots, \sigma_k)$.

سپس جهت‌های کانونی متناظر را به صورت زیر تعریف کنید:

$$A_k = \Sigma_{xx}^{-1/2} U_k, \qquad B_k = \Sigma_{yy}^{-1/2} V_k.$$

(و) (۳ نمره) نشان دهید این ماتریس‌ها در قیدهای CCA صدق می‌کنند، یعنی:

$$A_k^T \Sigma_{xx} A_k = I_k, \qquad B_k^T \Sigma_{yy} B_k = I_k.$$

(ز) (۴ نمره) نتیجه بگیرید مقدار بهینه برای k جهت کانونی (یعنی مجموع همبستگی‌های کانونی استخراج شده توسط k جهت) که با عبارت زیر توصیف می‌شود:

$$\text{trace}(A_k^T \Sigma_{xy} B_k)$$

برابر است با:

$$\sum_{i=1}^{k} \sigma_i(K).$$

سوال ۵ (۱۹ نمره)

در تئوری تصمیم‌گیری آماری، **ریسک (Risk)** به میانگین هزینه یا زیان مورد انتظاری گفته می‌شود که به دلیل عدم قطعیت در کلاس واقعی یک نمونه، متحمل می‌شویم. به ازای یک تصمیم α_i (انتخاب کلاس) و مشاهده ویژگی x، **ریسک شرطی** به صورت زیر تعریف می‌شود:

$$R(\alpha_i|x) = \sum_j \lambda_{ij} P(C_j|x)$$

که در آن λ_{ij} زیان (Loss) انتخاب کلاس α_i در حالی است که کلاس واقعی C_j است. **ریسک کل مورد انتظار** نیز با انتگرال‌گیری از ریسک شرطی روی تمام فضای ویژگی به دست می‌آید:

$$R = \int_{-\infty}^{\infty} R(\alpha(x)|x) p(x) dx$$

در ساده‌ترین حالت، با فرض **زیان ۰-۱** (که در آن $\lambda_{ij} = 0$ اگر $i = j$ و ۱ در غیر این صورت)، ریسک کل دقیقاً معادل **احتمال خطای طبقه‌بندی** خواهد بود:

$$R = P(\text{error}) = \int_{-\infty}^{\infty} \left(1 - \max_i P(C_i|x)\right) p(x) dx$$

اما در مسائل واقعی‌تر، ممکن است هزینه اشتباهات مختلف **نامتقارن** باشد (یعنی λ_{ij} مقادیر دلخواهی داشته باشد). در این شرایط، کمینه کردن ریسک دیگر معادل کمینه کردن صرفِ احتمال خطا نیست، بلکه مرز تصمیم‌گیری به گونه‌ای تغییر می‌کند که ریسک مورد انتظارِ حاصل از این هزینه‌های نامتقارن کمینه شود.

در مسائل طبقه‌بندی، هدف ما اختصاص یک برچسب کلاس به هر نمونه داده است به گونه‌ای که این ریسک (چه در حالت ۰-۱ و چه در حالت نامتقارن) کمینه شود. **مرز تصمیم‌گیری** مجموعه‌ای از نقاط در فضای ویژگی است که در آن‌ها سیستم طبقه‌بند بین دو یا چند کلاس مردد است؛ به بیان دقیق‌تر، در این مرز، «ریسک شرطی» یا هزینهٔ مورد انتظارِ انتخاب هر کلاس با یکدیگر برابر است.

برای به دست آوردن این مرز بهینه، از **قاعده تصمیم‌گیری بیز** استفاده می‌کنیم. در این قاعده، ابتدا **احتمال پسین** (Posterior Probability) هر کلاس با استفاده از **قضیه بیز** و با ترکیب اطلاعات پیشین و داده‌های مشاهده‌شده محاسبه می‌شود:

$$P(C_i|x) = \frac{p(x|C_i)P(C_i)}{p(x)} = \frac{p(x|C_i)P(C_i)}{\sum_j p(x|C_j)P(C_j)}$$

که در آن $p(x|C_i)$ چگالی احتمال شرطی (Likelihood)، $P(C_i)$ احتمال پیشین (Prior) و $p(x)$ چگالی حاشیه‌ای (Marginal Density) ویژگی x است.

- در **حالت زیان ۰-۱**، نمونه x به کلاسی تعلق می‌گیرد که احتمال پسین بیشتری داشته باشد و مرز تصمیم‌گیری جایی است که احتمالات پسین برابرند ($P(C_1|x) = P(C_2|x)$).
- اما در **حالت زیان نامتقارن**، این برابری باید با در نظر گرفتن ضرایب هزینه (λ_{ij}) بازتعریف شود تا ریسک شرطی کلاس‌ها در مرز تصمیم با هم برابر گردند.

فرض کنید می‌خواهیم مرز تصمیم‌گیری را برای حالتی به دست آوریم که یک کلاس از توزیع گوسی و کلاس دیگر از توزیع نمایی پیروی می‌کند. فضای ویژگی ۱ ـ بعدی است؛ لذا مرز تصمیم‌گیری مجموعهٔ کوچکی از نقاط خواهد بود.
ما دو کلاس داریم: کلاس N (نرمال) و کلاس E (نمایی).

- **کلاس نرمال (N):**
  - احتمال پیشین: $\pi_N = P(Y = N) = \frac{\sqrt{۲\pi}}{۱+\sqrt{۲\pi}}$
  - چگالی احتمال:

$$P(X = x|Y = N) = \frac{۱}{\sqrt{۲\pi}\sigma} e^{-\frac{x^۲}{۲\sigma^۲}}$$

- **کلاس نمایی (E):**
  - احتمال پیشین: $\pi_E = P(Y = E) = \frac{۱}{۱+\sqrt{۲\pi}}$
  - چگالی احتمال:

$$P(X = x|Y = E) = \begin{cases} \lambda e^{-\lambda x}, & x \geq ۰ \\ ۰, & x < ۰ \end{cases}$$

(الف) (۸ نمره) رابطهٔ مرز تصمیم‌گیری را بر حسب x و σ بنویسید. توجه کنید که فقط مقادیر مثبت x اهمیت دارد (زیرا برای $x < ۰$ چگالی کلاس نمایی صفر است). معادلهٔ خود را تا جایی ساده کنید که بر حسب x از نوع درجهٔ دوم (quadratic) باشد. نیازی به حل کامل معادله نیست. (*فرض: زیان ۰-۱*)

(ب) (۶ نمره) نشان دهید تعداد نقاط مرز تصمیم‌گیری فقط به حاصل‌ضرب بدون بعد $t = \sigma\lambda$ بستگی دارد. دقیقاً تعیین کنید به ازای چه مقادیری از t مرز دارای یک نقطه و به ازای چه مقادیری دو نقطه است و حالت مرزی را نیز بررسی کنید. سپس در هر حالت، نواحی تصمیم‌گیری R_N (ناحیه‌ای که به کلاس نرمال اختصاص می‌یابد) و R_E (ناحیه‌ای که به کلاس نمایی اختصاص می‌یابد) را روی محور حقیقی به‌صورت صریح بنویسید.

(ج) (۵ نمره) اکنون فرض کنید زیان‌های تصمیم نامتقارن‌اند: زیان تصمیم E در حالی که کلاس واقعی N است برابر $c > ۰$ و زیان تصمیم N در حالی که کلاس واقعی E است برابر ۱ است. معادلهٔ مرز تصمیم‌گیریِ کمینه‌کنندهٔ ریسک مورد انتظار را به دست آورید و نشان دهید تمام نتایج قسمت (ب) با جایگزینی پارامتر t با t/c برقرار می‌ماند. تفسیر کنید که افزایش c چگونه نواحی تصمیم‌گیری را جابه‌جا می‌کند.