به نام خدا

۱. محاسبات **Forward and Backward** در شبکه‌های کانولوشنی

فرض کنید ماتریس ورودی X و کرنل W به‌صورت زیر داده شده‌اند:

$$X = \begin{bmatrix} ۱ & ۲ & ۰ & ۳ & ۱ \\ ۲ & ۱ & ۳ & ۰ & ۲ \\ ۰ & ۱ & ۲ & ۱ & ۱ \\ ۳ & ۰ & ۱ & ۲ & ۰ \\ ۱ & ۲ & ۱ & ۰ & ۳ \end{bmatrix}, \quad W = \begin{bmatrix} ۱ & ۰ & -۱ \\ ۰ & ۲ & ۱ \\ -۱ & ۱ & ۰ \end{bmatrix}$$

در این مسئله، کانولوشن با گام (Stride) برابر ۲ و پدینگ (Padding) برابر ۱ انجام می‌شود.

(الف) خروجی کانولوشن $Y = X * W$ را محاسبه کنید. ابعاد خروجی را مشخص کرده و مقدار هر درایه را بنویسید.

(ب) اگر تابع هزینه به‌صورت

$$\mathcal{L} = \frac{۱}{۲} \sum_{i,j} (Y_{ij} - T_{ij})^۲$$

تعریف شود، مشتقات زیر را استخراج کنید:

$$\frac{\partial \mathcal{L}}{\partial Y}, \quad \frac{\partial \mathcal{L}}{\partial W}, \quad \frac{\partial \mathcal{L}}{\partial X}$$

نتیجه را به‌صورت ماتریسی بنویسید و توضیح دهید که پدینگ و گام چگونه بر ابعاد و مقادیر مشتقات اثر می‌گذارند.

۲. معماری‌های کارآمد، **ShuffleNet** و کانولوشن عمقی تفکیک‌پذیر (**Depthwise Separable Convolution**)

در سال‌های اخیر، روند طراحی شبکه‌های عصبی کانولوشنی (CNN) به سمت مدل‌های عمیق‌تر و بزرگ‌تر برای دستیابی به دقت بالاتر حرکت کرده است. با این حال، در بسیاری از کاربردهای عملی مانند تلفن‌های هوشمند، منابع محاسباتی بسیار محدود بوده و بودجهٔ محاسباتی معمولاً در حد ده‌ها تا چند صد مگافلاپس (MFLOPs) است. از این‌رو، تلاش بسیاری برای طراحی معماری‌های کارآمد انجام شده است که بتوانند در چنین محدودیت‌هایی عملکرد مناسبی ارائه دهند. در این سوال به بررسی ایده‌های معماری ShuffleNet می‌پردازیم که منجر به عملکرد مناسب به ازای بودجهٔ محاسباتی محدود می‌شود. این معماری با کاهش هزینهٔ محاسباتی اجزای اصلی شبکه، موفق به ارائهٔ شبکه‌های بزرگ اما کارآمد شده است.

کانولوشن عمقی تفکیک‌پذیر (**Depthwise Separable Convolution**)

(الف) هزینهٔ محاسباتی کانولوشن استاندارد را برای اندازهٔ ورودی $H \times W$، تعداد کانال ورودی C_{in}، تعداد کانال خروجی C_{out} و اندازهٔ فیلتر K برحسب FLOPs محاسبه کنید. فرض کنید طول گام برابر یک است و با استفاده از Padding ابعاد مکانی حفظ می‌شود.

(ب) کانولوشن عمقی تفکیک‌پذیر یک روش برای کاهش هزینهٔ محاسباتی کانولوشن استاندارد می‌باشد. این روش را به‌طور کامل توضیح دهید.

(ج) مشابه بخش (الف)، هزینهٔ محاسباتی کانولوشن عمقی تفکیک‌پذیر را به‌دست آورید و با کانولوشن استاندارد مقایسه کنید.

(د) بررسی‌های عملی نشان می‌دهند کانولوشن عمقی تفکیک‌پذیر جایگزین مناسبی برای کانولوشن است. فرض کنید ماتریس کانولوشن به فرم $W \in \mathbb{R}^{C_{\text{out}} \times K^۲ C_{\text{in}}}$ مورد استفاده قرار می‌گیرد. بنابراین برای هر قطعهٔ $K \times K$ که به فرم $x \in \mathbb{R}^{K^۲ C_{\text{in}}}$ تبدیل می‌شود، می‌توان حاصل عملیات لایهٔ کانولوشن را به‌صورت ضرب ماتریسی نمایش داد. ثابت کنید:

(آ) کانولوشن عمقی تفکیک‌پذیر، ماتریس کانولوشن W را به‌شکل ضرب دو ماتریس نمایش می‌دهد.

(ب) این ضرب ماتریسی به ازای ماتریس دلخواه W دقیق نخواهد بود.

(ج) با فرض برابر بودن رتبهٔ ضرب این دو ماتریس با r، این ضرب ماتریسی در حالت کلی بهترین تقریب رنک r از ماتریس W در نرم طیفی نخواهد بود.

۳. کانولوشن گروهی (Group Convolution)

در بسیاری از شبکه‌های کانولوشنی، بخش قابل توجهی از هزینه محاسباتی شبکه مربوط به کانولوشن‌های ۱×۱ است. همچنین در بخش قبل کاربرد این نوع کانولوشن را دیدیم.

(ه) توضیح دهید که کانولوشن ۱×۱ به چه منظور در معماری‌هایی مانند GoogLeNet و ResNet استفاده می‌شود.

(و) معماری ShuffleNet برای کاهش سربار محاسباتی کانولوشن ۱×۱ از ایدهٔ کانولوشن گروهی استفاده می‌کند. این روش را توضیح دهید.

(ز) هزینه محاسباتی کانولوشن گروهی را برای اندازه ورودی $H \times W$، تعداد کانال ورودی C_{in}، تعداد کانال خروجی C_{out}، تعداد گروه g و اندازه فیلتر K بر حسب FLOPs محاسبه کنید. فرض کنید طول گام برابر یک است و با استفاده از padding ابعاد مکانی حفظ می‌شود. آیا این روش منجر به بهبود هزینه محاسباتی در ۱×۱ می‌شود؟

۴. الگوریتم پس‌انتشار و چالش‌های آن برای RNN

بخش اول

یک نسخهٔ ساده و تک‌بعدی RNN را به‌شکل زیر فرض کنید:

$$h_t = \tanh(w \cdot h_{t-۱}), \quad t \in \mathbb{N}$$

که در آن $h_t \in \mathbb{R}$ نشان‌گر حالت پنهان شبکه و $w \in \mathbb{R}$ پارامتر قابل یادگیری است. همچنین فرض نمایید این شبکه تنها در گام پایانی Tـام خروجی می‌دهد به‌طوری که:

$$\hat{y} = h_T.$$

برای تابع اتلاف نیز تابع مربعات خطا به‌شکل زیر برای برچسب y^* استفاده می‌شود:

$$\mathcal{L} = \frac{۱}{۲}(h_T - y^*)^۲.$$

برای آموزش شبکه‌های RNN از الگوریتم پس‌انتشار در طول زمان (Backpropagation Through Time) استفاده می‌شود؛ در این راستا نشان دهید رابطهٔ گرادیان خطا نسبت به پارامتر مدل، به‌شکل زیر است:

$$\frac{\partial \mathcal{L}}{\partial w} = (h_T - y^*) \sum_{t=1}^{T} w^{T-t} \cdot (1 - h_t^2) h_{t-1} \cdot \prod_{j=t+1}^{T} (1 - h_j^2)$$

یادآوری: توجه کنید که رابطهٔ $\frac{d}{dx}\tanh(x) = 1 - \tanh^2(x)$ برقرار است.

بخش دوم

(الف) فرض کنید $\gamma_i := w \cdot (1 - h_i^2)$. بازهٔ مقادیر ممکن برای $|\gamma_i|$ را مشخص نمایید.

(ب) گام مشخص t را در نظر بگیرید و طول دنباله را $T \to \infty$ فرض کنید. مشخص نمایید تحت چه شرایطی چالش محو شدن گرادیان (Gradient Vanishing) رخ می‌دهد؟

(ج) گام مشخص t را در نظر بگیرید و طول دنباله را $T \to \infty$ فرض کنید. مشخص نمایید تحت چه شرایطی چالش انفجار گرادیان (Exploding Gradient) رخ می‌دهد؟

۵. مقایسهٔ معماری‌های LSTM و GRU

در درس با دو معماری LSTM و GRU به تفصیل آشنا شده‌اید. در این پرسش قصد داریم این دو معماری را با یکدیگر مقایسه نماییم و نشان دهیم تحت فرضیاتی این دو مدل هم‌ارز خواهند بود. در ادامه برای یادآوری، روابط این دو معماری آورده شده است:

مدل LSTM:

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i) \quad \text{(گیت ورودی)}$$

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f) \quad \text{(گیت فراموشی)}$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \quad \text{(گیت خروجی)}$$

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

$$h_t = o_t \odot \tanh(c_t)$$

مدل GRU:

$$z_t = \sigma(W_z x_t + U z h_{t-1} + b_z) \quad \text{(گیت به‌روزرسانی)}$$

$$r_t = \sigma(W_r x_t + U r h_{t-1} + b_r) \quad \text{(گیت بازنشانی)}$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h(r_t \odot h_{t-1}) + b_h)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

بخش اول

فرض کنید در مدل LSTM، گیت خروجی همواره باز است یعنی $o_t = 1$ و مقدار h_t بدون تابع فعال‌سازی tanh محاسبه می‌شود. همچنین در نظر بگیرید گیت‌های ورودی و فراموشی مکمل یکدیگر رفتار می‌کنند یعنی $f_t = 1 - i_t$ است.

(الف) با توجه به فرضیات فوق، h_t را به‌عنوان تابعی از i_t، x_t و h_{t-1} بازنویسی کنید.

(ب) رابطهٔ بازنویسی‌شده برای h_t را با مدل GRU مقایسه کنید. شباهت و تفاوت آن دو را توضیح دهید.

بخش دوم

(ج) نقش گیت بازنشانی r_t در مدل GRU را توصیف کنید و برای مدل LSTM تغییری در رابطهٔ $\tilde{c}_t$ بدهید به‌طوری که بتواند توانایی مشابه با گیت بازنشانی مدل GRU پیدا کند.

(د) با استفاده از نقش گیت‌ها در مدل GRU و مدل LSTM با تغییرات فوق، توضیح دهید هر کدام از فرضیات به چه معنایی هستند و شباهت این دو مدل را بررسی کنید.

۶. جریان گرادیان و معماری‌های کمینهٔ RNN

قبلاً بررسی کردید که چگونه شبکه‌های بازگشتی استاندارد از مشکل محو شدن گرادیان رنج می‌برند و چگونه معماری‌هایی مانند LSTM و GRU با استفاده از مکانیزم‌های گیت‌گذاری این مشکل را کاهش می‌دهند. در این پرسش، قصد داریم جریان گرادیانِ حالت سلول را در یک LSTM از نظر ریاضی تحلیل کنیم و سپس به بررسی یک نسخهٔ سفارشی و بسیار ساده‌شده از GRU بپردازیم.

بخش اول: چرخ‌وفلک خطای ثابت در LSTM (**Constant Error Carousel**)

معادلهٔ اصلی به‌روزرسانی برای حالت سلول c_t در LSTM به‌صورت زیر است:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

که در آن f_t گیت فراموشی، i_t گیت ورودی، و $\tilde{c}_t$ حالت سلول کاندید است.

(الف) در فرمول‌بندی اصلی LSTM، برای جلوگیری از انفجار یا محو شدن گرادیان از طریق مسیرهای پیچیده، خطا بریده (Truncate) می‌شود. فرض کنید گرادیان‌های گیت‌ها (f_t, i_t) و حالت کاندید ($\tilde{c}_t$) نسبت به c_{t-1} برابر صفر در نظر گرفته شوند (یعنی ما تنها مسیر خطی مستقیم حالت سلول را در نظر می‌گیریم). تحت این فرض، گرادیان محلی $\dfrac{\partial c_t}{\partial c_{t-1}}$ را به دست آورید.

(ب) با استفاده از نتیجهٔ بخش (الف)، گرادیان کلی $\dfrac{\partial c_T}{\partial c_t}$ را روی دنباله‌ای به طول T محاسبه کنید. از نظر ریاضی توضیح دهید که چگونه تنظیم بایاس گیت فراموشی b_f روی یک عدد مثبت بزرگ در زمان مقداردهی اولیه، به کاهش مشکل محو شدن گرادیان کمک می‌کند. این رفتار را با یک شبکهٔ استاندارد RNN مقایسه کنید.

بخش دوم: واحد گیت‌دار کمینه (**Minimal Gated Unit**)

برای کاهش بار محاسباتی معماری GRU (که دارای دو گیت به‌روزرسانی z_t و بازنشانی r_t است)، محققان معماری واحد گیت‌دار کمینه (Minimal Gated Unit) را پیشنهاد دادند که گیت‌های بازنشانی و به‌روزرسانی را در یک گیت فراموشی f_t ترکیب می‌کند. MGU به‌صورت زیر تعریف می‌شود:

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h(f_t \odot h_{t-1}) + b_h)$$

$$h_t = (1 - f_t) \odot h_{t-1} + f_t \odot \tilde{h}_t$$

(ج) معادلات MGU را با GRU استاندارد مقایسه کنید. به‌طور مشخص، گیت‌های GRU استاندارد (z_t و r_t) را برحسب گیت f_t در MGU بیان کنید تا نشان دهید چگونه MGU یک حالت خاص از معماری GRU است.

(د) رفتار دقیق MGU را در مقایدر حدی تابع فعال‌ساز سیگموئید تعیین کنید:

- حالت ۱: اگر برای تمام ابعاد $f_t \to ۱$ میل کند چه اتفاقی می‌افتد؟ در این حالت MGU دقیقاً رفتار کدام معماری کلاسیک را تقلید می‌کند؟
- حالت ۲: اگر برای تمام ابعاد $f_t \to ۰$ میل کند چه اتفاقی می‌افتد؟ کاربرد عملی این حالت برای مدل‌سازی توالی‌ها چیست؟