به نام خدا

۱. تحلیل افزونگی، هرس و مکانیسم گیت‌گذاری در Multi-Head Attention

در لایهٔ توجه چندسر (Multi-Head Attention)، ورودی‌ها از طریق نگاشت‌های خطی مختلف (projections) به چند زیرفضای بازنمایی نگاشت می‌شوند:

$$\text{head}_i = \text{Attention}\left(QW_i^Q, KW_i^K, VW_i^V\right), \quad W_i^Q, W_i^K, W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_k}, \quad d_k = \frac{d_{\text{model}}}{h}$$

سپس خروجی تمام هدها الحاق شده و در ماتریس تصویر نهایی $W^O \in \mathbb{R}^{d_{\text{model}} \times d_{\text{model}}}$ ضرب می‌شود:

$$\text{MHA}(Q, K, V) = \text{Concat}(\text{head}_1, \ldots, \text{head}_h)W^O$$

(الف) فرض کنید همهٔ هدها دقیقاً از ماتریس‌های تصویر یکسانی استفاده کنند؛ یعنی برای هر $1 \le i, j \le h$ داشته باشیم:

$$W_i^Q = W_j^Q, \quad W_i^K = W_j^K, \quad W_i^V = W_j^V$$

نشان دهید در این حالت، MHA در عمل یک الگوی توجه یکسان را چندین بار تکرار می‌کند و خروجی آن را می‌توان به‌صورت یک لایهٔ توجه تک‌سر (Single-Head Attention) همراه با یک ماتریس تصویر خروجی مؤثر بازنویسی کرد. توجه کنید که این حالت لزوماً فقط معادل ضرب در یک ضریب مقیاس ساده نیست، مگر آن‌که ماتریس خروجی W^O ساختار خاصی داشته باشد. این نتیجه چه مفهومی را دربارهٔ اهمیت تنوع بین هدهای توجه یادگرفته‌شده نشان می‌دهد؟

(ب) مطالعات تجربی نشان داده‌اند که برخی هدهای توجه روی پدیده‌های زبانی خاص، مانند وابستگی‌های نحوی یا coreference، تخصص پیدا می‌کنند؛ با این حال، بسیاری از هدها نیز افزونه یا تکراری هستند و حذف آن‌ها آسیب جدی به عملکرد مدل نمی‌زند. اگر فقط بتوانید k هد را نگه دارید ($k < h$)، یک روش اصولی برای حذف هدهای کم‌اهمیت پیشنهاد دهید که هر دو جنبهٔ زیر را در نظر بگیرد:

آ) اهمیت هر هد به‌صورت جداگانه.

ب) افزونگی یا شباهت بین هدهای مختلف.

(ج) اکنون می‌خواهیم یک روش معماری‌محور برای انتخاب خودکار هدهای مفید طراحی کنیم (برای ایده گرفتن می‌توانید به مقالات Voita et al.، ۲۰۱۹ و Michel et al.، ۲۰۱۹ مراجعه کنید). فرض کنید خروجی هد iـام را با H_i نشان دهیم و برای هر هد یک متغیر دروازه‌ای یادگرفتنی $z_i \in [0, 1]$ تعریف کنیم:

$$\text{MHA}_{\text{gated}}(Q, K, V) = \text{Concat}(z_1 H_1, z_2 H_2, \ldots, z_h H_h)W^O$$

هدف این است که پس از آموزش، فقط تعداد کمی از هدهای مهم باقی بمانند و هدهای کم‌اهمیت یا تکراری حذف شوند.

آ) یک تابع اتلاف برای آموزش این دروازه‌ها طراحی کنید که شامل سه بخش باشد: تابع اتلاف وظیفه اصلی ($\mathcal{L}_{\text{task}}$) برای حفظ عملکرد مدل، یک جملهٔ تنک‌سازی برای تشویق مدل به استفاده از تعداد کمتر هدها، و یک جریمهٔ افزونگی برای جلوگیری از نگه‌داشتن هدهایی که رفتار بسیار مشابه دارند. اگر A_i ماتریس توجه هد iـام باشد و شباهت دو

هد به‌صورت زیر تعریف شود:

$$R(i,j) = \cos\left(\mathrm{vec}(A_i), \mathrm{vec}(A_j)\right)$$

یک فرم مناسب برای کل تابع هزینه بنویسید و توضیح دهید هر جمله چه نقشی دارد.

ب) توضیح دهید پس از آموزش، چگونه می‌توان از مقادیر دروازه‌ها برای انتخاب k هد نهایی استفاده کرد.

ج) در پایان تحلیل کنید اگر دو هد رفتار کاملاً یکسانی داشته باشند، چرا وجود جریمهٔ افزونگی باعث می‌شود نگه‌داشتن هم‌زمان هر دو هد مطلوب نباشد؟

۲. تحلیل جریان گرادیان، پایداری و جایگاه نرمال‌سازی لایه‌ای در ترنسفورمرها

معماری اصلی ترنسفورمر از چیدمان Post-LN استفاده می‌کند:

$$x_{l+1} = \mathrm{LN}(x_l + \mathrm{Sublayer}(x_l))$$

در حالی که در بسیاری از معماری‌های مدرن‌تر، از فرمول‌بندی Pre-LN بهره گرفته می‌شود:

$$x_{l+1} = x_l + \mathrm{Sublayer}(\mathrm{LN}(x_l))$$

(الف) جریان گرادیان را در یک بلوک با اتصال باقی‌مانده (residual block) تحلیل کنید.

آ) برای حالت Post-LN، گرادیان تابع اتلاف نسبت به ورودی لایه یعنی $\frac{\partial \mathcal{L}}{\partial x_l}$ را برحسب گرادیان لایهٔ بعدی یعنی $\frac{\partial \mathcal{L}}{\partial x_{l+1}}$ به دست آورید. نشان دهید که ماتریس ژاکوبین لایهٔ LN چگونه می‌تواند اندازه و جهت گرادیان بازگشتی را دستخوش تغییر کند.

ب) رفتار فوق را با حالت Pre-LN مقایسه کنید. توجه کنید که در Pre-LN، مسیر باقی‌مانده (residual branch) مستقیماً از نرمال‌سازی لایه‌ای عبور نمی‌کند.

ج) توضیح دهید چرا ساختار Pre-LN آموزش مدل‌های عمیق‌تر را به شکل چشمگیری پایدارتر می‌کند و در اغلب پیکربندی‌ها، وابستگی به مرحلهٔ گرم‌کردن نرخ یادگیری (learning-rate warmup) را کاهش داده یا حتی حذف می‌نماید.

(ب) با وجود پایداری بهتر در فرآیند آموزش، مدل‌های آموزش‌دیده با Pre-LN در مقیاس‌های کوچک‌تر گاهی عملکرد نهایی کمی ضعیف‌تر نسبت به مدل‌های دارای ساختار Post-LN از خود نشان می‌دهند. یک تحلیل منطقی برای این پدیده ارائه دهید و در بررسی خود به موارد زیر اشاره کنید:

آ) عمق مؤثر در تبدیل ویژگی‌ها (effective depth of transformations).

ب) توزیع فعال‌سازی‌ها (activations) در هنگام ورود به لایه‌های نهایی شبکه.

ج) نقش ساختار نرمال‌سازی به‌عنوان نوعی منظم‌ساز درون‌زا (implicit regularization).

(ج) برخی پژوهش‌ها و معماری‌های جدید به سمت استفاده از روش‌های نرمال‌سازی ترکیبی یا حتی حذف کامل لایه‌های نرمال‌سازی پیش رفته‌اند و در عوض، از تنظیم دقیق مقداردهی اولیه یا مقیاس‌بندی مناسب شاخهٔ باقی‌مانده استفاده می‌کنند.

آ) یک نمونه از این روش‌ها (مانند Fixup initialization، T-Fixup، DeepNorm یا روش‌های مشابه) را به اختصار توضیح دهید.

ب) از دیدگاه نظری تبیین کنید که اگر مقداردهی اولیه، مقیاس‌بندی شاخهٔ باقی‌مانده و دینامیک جریان گرادیان به‌درستی هدایت و تنظیم شوند، چرا ممکن است لایه‌های نرمال‌سازی برای آموزش پایدار مدل دیگر ضروری نباشند؟

۳. مقایسهٔ روش‌های بهینه‌سازی پارامتر (**LoRA**) و مقیاس‌پذیری زمان استنتاج (**Inference-Time Scaling**)

در مدل‌های زبانی بزرگ، دو راهکار عمده برای ارتقای عملکرد بدون بازآموزی کامل تمام پارامترها وجود دارد: راهکار نخست، بهره‌گیری از روش‌های کارآمد از نظر پارامتر در فاز تنظیم دقیق مانند LoRA است. راهکار دوم، ثابت نگه‌داشتن وزن‌های مدل و تخصیص توان محاسباتی بیشتر در زمان استنتاج، نظیر راهبردهای خودسازگاری (Self-Consistency) یا استفاده از بازبین (Verifier) است. در این مسئله، این دو رویکرد را از منظر تعداد پارامتر، هزینهٔ استنتاج و کارایی مقایسه می‌کنیم.

(الف) در روش LoRA، ماتریس وزن اصلی $W \in \mathbb{R}^{d\times k}$ ثابت نگه داشته شده و به‌روزرسانی کم‌رتبه‌ای به آن افزوده می‌شود:

$$W' = W + \Delta W, \quad \Delta W = BA$$

که در آن $B \in \mathbb{R}^{d\times r}$ و $A \in \mathbb{R}^{r\times k}$ بوده و $r \ll \min(d,k)$ رتبهٔ تجزیه است.

آ) نشان دهید تعداد پارامترهای قابل آموزش در LoRA برابر با $r(d+k)$ است؛ در حالی که تنظیم دقیق کامل به آموزش $d \times k$ پارامتر نیاز دارد.

ب) برای یک ماتریس نگاشت با ابعاد $d = k = ۴۰۹۶$ و رتبهٔ $r = ۸$، مقادیر زیر را محاسبه کنید:

- تعداد پارامترهای قابل آموزش در تنظیم دقیق کامل
- تعداد پارامترهای قابل آموزش در LoRA
- درصد کاهش تعداد پارامترهای قابل آموزش

(ب) از دیدگاه شهودی و تئوری، توضیح دهید چرا یک به‌روزرسانی کم‌رتبه به فرم $\Delta W = BA$ می‌تواند برای تطبیق یک مدل ازپیش‌آموزش‌دیدهٔ بزرگ با وظایف جدید اثربخش باشد. در پاسخ خود به مفهوم «بعد ذاتی» (intrinsic dimension) تغییرات در فضای وزن‌ها اشاره کنید.

سپس دو رویکرد پیاده‌سازی LoRA در زمان استنتاج یعنی محاسبهٔ مجزای $Wx + BAx$ در برابر ادغام پیشین وزن‌ها $W' = W + BA$ را از جنبه‌های زیر مقایسه نمایید:

آ) تأخیر زمانی استنتاج (inference latency)

ب) میزان مصرف حافظه (memory footprint)

ج) انعطاف‌پذیری در سرویس‌دهی همزمان چندین ادپتر مختلف (multi-tenant serving)

(ج) فرض کنید وزن‌های مدل ثابت هستند و قصد داریم تنها با تخصیص توان محاسباتی در زمان استنتاج، احتمال دستیابی به پاسخ صحیح را افزایش دهیم. برای یک مسئلهٔ استدلالی، احتمال درستی یک پاسخ منفرد برابر با $p = ۰/۳۵$ است. مدل N پاسخ مستقل تولید می‌کند و سپس یک بازبین (Verifier) یکی از پاسخ‌ها را برمی‌گزیند. اگر دست‌کم یک پاسخ درست میان N پاسخ وجود داشته باشد، بازبین با احتمال $r = ۰/۸$ پاسخ درست را انتخاب می‌کند؛ در غیر این صورت پاسخ نهایی قطعاً نادرست خواهد بود.

آ) فرمول بستهٔ احتمال درستی پاسخ نهایی (P_N) را برحسب N، p و r به دست آورید.

ب) مقدار عددی P_N را به‌ازای مقادیر $N \in \{۱, ۲, ۴, ۸\}$ محاسبه کنید.

ج) نشان دهید سود حاشیه‌ای تولید نمونه‌های بیشتر یعنی $P_N - P_{N-۱}$ با افزایش N تابعی اکیداً نزولی است (قانون بازده نزولی).

(د) فرض کنید بودجهٔ کل برای زمان استنتاج برابر با ۶۰۰۰ توکن پردازش‌شده (مجموع توکن‌های ورودی و تولیدشده) است. دو راهبرد زیر را در نظر بگیرید:

- راهبرد اول (یادگیری درون‌زمینه): صورت سؤال شامل ۲۰۰ توکن است و به ازای هر مثال حل‌شدهٔ افزوده به ورودی (k)، ۲۰۰ توکن به طول پرامپت اضافه می‌شود. مدل در پایان یک پاسخ ۴۰۰ توکنی تولید می‌کند. دقت مدل به‌ازای $۰ \le k \le ۵$ از رابطهٔ $p_A(k) = ۰/۳۵ + ۰/۰۸k$ پیروی می‌کند.

- راهبرد دوم (خودسازگاری با بازبین): پرامپت ورودی بدون مثال بوده و تنها ۲۰۰ توکن صورت سؤال است. مدل برای هر نمونه یک پاسخ ۴۰۰ توکنی تولید می‌کند (هزینهٔ هر زنجیره برابر ۶۰۰ توکن). احتمال درستی هر نمونه منفرد $p = ۰/۴۵$ بوده و بازبین مشابه بخش قبل با احتمال $r = ۰/۸$ پاسخ درست را (در صورت وجود حداقل یکی) برمی‌گزیند.

مطلوب است:

آ) بیشترین مقدار مجاز k با توجه به محدودیت بودجه در راهبرد اول و دقت نهایی متناظر با آن

ب) بیشترین تعداد پاسخ‌های قابل تولید (N) در راهبرد دوم و دقت نهایی حاصل از آن

ج) مقایسه و تعیین راهبرد برتر بر اساس فرضیات مسئله

(ه) در قالب یک پاراگراف جمع‌بندی کنید که بهره‌گیری از LoRA در چه شرایطی مناسب‌تر است و در چه مسائلی مقیاس‌پذیری زمان استنتاج ترجیح دارد؟ در تحلیل خود به تفاوت هزینهٔ آموزش و استنتاج، وظایف با استدلال موردی در برابر تسک‌های پرتکرار، و پتانسیل ترکیب همزمان این دو رویکرد اشاره نمایید.

۴. تحلیل کارایی پارامتری روش‌های Prompt Tuning و Prefix Tuning

فرض کنید یک مدل زبانی پیش‌آموزش‌دیده مبتنی بر ترنسفورمر با مشخصات زیر در اختیار داریم:

- تعداد لایه‌های ترنسفورمر: $L = ۲۴$
- بعد حالت پنهان: $d = ۱۰۲۴$
- تعداد هدهای توجه: $h = ۱۶$
- تعداد کل پارامترها: ۳۵۰ میلیون (۳۵۰M)

می‌خواهیم این مدل را برای ۲۰ وظیفهٔ پایین‌دستی (downstream tasks) مجزا سازگار کنیم. سه رویکرد Full Fine-Tuning، Prompt Tuning و Prefix Tuning را در نظر گرفته و به پرسش‌های زیر پاسخ دهید.

(الف) در روش تنظیم دقیق کامل (Full Fine-Tuning)، به ازای هر وظیفه تمامی ۳۵۰ میلیون پارامتر مدل به‌روزرسانی شده و یک نسخهٔ کامل و مجزا از مدل برای هر وظیفه بر روی دیسک ذخیره می‌شود. محاسبه کنید در مجموع برای ۲۰ وظیفه چند پارامتر اختصاصی باید ذخیره شود؟

(ب) در روش Prompt Tuning، پارامترهای مدل پایه ثابت نگه داشته می‌شوند و تنها یک پیشوند نرم (soft prompt) با طول $m = ۵۰$ به ازای هر وظیفه آموزش داده می‌شود؛ به طوری که بعد هر بردار پرامپت برابر با $d = ۱۰۲۴$ است. در این سناریو، تنها پارامترهای اختصاصی هر وظیفه همین بردارهای پرامپت هستند و یک نسخهٔ واحد از مدل پایه به اشتراک گذاشته می‌شود. مطلوب است محاسبهٔ:

آ) تعداد پارامترهای آموزش‌پذیر به ازای هر وظیفه

ب) مجموع کل پارامترهای اختصاصی ذخیره‌شده برای هر ۲۰ وظیفه

(ج) در روش Prefix Tuning، پارامترهای مدل پایه دست‌نخورده باقی می‌مانند، اما در تمام $L = ۲۴$ لایهٔ ترنسفورمر، به ازای هر وظیفه $p = ۱۰$ بردار پیشوند برای کلیدها (K) و $p = ۱۰$ بردار پیشوند برای مقادیر (V) در مکانیزم توجه یاد گرفته می‌شود. فرض کنید بعد هر بردار پیشوند $d = ۱۰۲۴$ است و از هزینهٔ بازپارامترسازی با شبکهٔ MLP صرف‌نظر می‌کنیم. مطلوب است محاسبهٔ:

آ) تعداد پارامترهای آموزش‌پذیر به ازای هر وظیفه

ب) مجموع کل پارامترهای اختصاصی ذخیره‌شده برای هر ۲۰ وظیفه

(د) نسبت کاهش حجم ذخیره‌سازی پارامترهای اختصاصی وظیفه را در مقایسه با روش Full Fine-Tuning برای هر یک از روش‌های زیر محاسبه کنید:

آ) روش Prompt Tuning

ب) روش Prefix Tuning

(ه) تفاوت ساختاری اصلی میان Prompt Tuning و Prefix Tuning را از دیدگاه محل مداخله در گراف محاسباتی ترنسفورمر توضیح دهید. برای هر یک از این دو روش، دست‌کم یک مزیت و یک محدودیت بارز (از نظر ظرفیت بیانی مدل، سهولت بهینه‌سازی یا طول مؤثر توالی) بیان نمایید.

۵. تحلیل ریاضی جای‌گذاری موقعیت: از **Sinusoidal PE** تا **RoPE**

در شبکه‌های ترنسفورمر، سازوکار توجه به خود (Self-Attention) ذاتاً به ترتیب توکن‌ها حساس نیست؛ بنابراین لازم است اطلاعات مکانی و ترتیبی به نحوی وارد محاسبات مدل شود. در این پرسش، ابتدا ویژگی‌های تقارن و جابه‌جایی را در کدگذاری مکانی سینوسی (Sinusoidal Positional Encoding) بررسی می‌کنیم و سپس نشان می‌دهیم که چگونه روش جای‌گذاری موقعیت چرخشی (Rotary Positional Embedding یا RoPE) اطلاعات فاصلهٔ نسبی را مستقیماً وارد ضرب داخلی توجه می‌کند.

(الف) در کدگذاری موقعیت سینوسی ترنسفورمر، برای موقعیت زمانی t و به ازای هر جفت‌بعد i بردار دوبعدی زیر تعریف می‌شود:

$$p_i(t) = \begin{bmatrix} \sin(\omega_i t) \\ \cos(\omega_i t) \end{bmatrix}, \quad \omega_i = \frac{1}{10000^{2i/d}}$$

آ) نشان دهید برای هر جابه‌جایی ثابت k یک ماتریس خطی $A_i(k) \in \mathbb{R}^{2\times 2}$ وجود دارد به‌طوری که:

$$p_i(t+k) = A_i(k)\, p_i(t)$$

ماتریس $A_i(k)$ را صریحاً به دست آورید.

ب) نشان دهید که رابطهٔ $A_i(k_1+k_2) = A_i(k_1)A_i(k_2)$ برقرار است. این رابطه چه مفهومی دربارهٔ پیوستگی و ساختار جبری جابه‌جایی‌ها در کدگذاری سینوسی بیان می‌کند؟

(ب) برای دو موقعیت اختیاری m و n:

آ) نشان دهید حاصل‌ضرب داخلی مؤلفه‌ها برابر است با:

$$p_i(m)^\top p_i(n) = \cos(\omega_i(m-n))$$

ب) فرض کنید بردار کامل کدگذاری موقعیت $\mathrm{PE}(t)$ از الحاق تمام مؤلفه‌های دوبعدی $p_i(t)$ تشکیل شده باشد. نشان دهید:

$$\mathrm{PE}(m)^\top \mathrm{PE}(n) = \sum_{i=0}^{d/2-1} \cos(\omega_i(m-n))$$

نتیجه بگیرید که شباهت ضرب داخلی دو بردار مکانی، صرفاً تابعی از فاصلهٔ نسبی $m-n$ است و به موقعیت‌های مطلق m و n وابسته نیست.

(ج) یک امتیاز مکانی کلی‌تر را به‌صورت زیر در نظر بگیرید که در آن $B \in \mathbb{R}^{d\times d}$ می‌تواند نمایانگر ماتریس تبدیل مؤثر $W_Q W_K^\top$

در ضرب توجه باشد:

$$g_B(m,n) = \mathrm{PE}(m)^\top B\,\mathrm{PE}(n)$$

فرض کنید ماتریس B نسبت به جفت‌ابعاد دوبعدی سینوسی، بلوکی‌ـقطری باشد و هر بلوک ۲×۲ آن به‌صورت زیر فرمول‌بندی شود:

$$B_i = a_i I + b_i J, \quad I = \begin{bmatrix} ۱ & ۰ \\ ۰ & ۱ \end{bmatrix}, \quad J = \begin{bmatrix} ۰ & -۱ \\ ۱ & ۰ \end{bmatrix}$$

آ) نشان دهید رابطهٔ زیر برقرار است:

$$p_i(m)^\top B_i p_i(n) = a_i \cos(\omega_i(m-n)) + b_i \sin(\omega_i(n-m))$$

و نتیجه بگیرید که در این حالت نیز $g_B(m,n)$ تنها به فاصلهٔ نسبی $m-n$ وابسته است.

ب) توضیح دهید آیا برای یک ماتریس دلخواه و عمومی B، مقدار $g_B(m,n)$ لزوماً تابعی از فاصلهٔ نسبی $m-n$ باقی می‌ماند یا وابستگی به موقعیت مطلق پدیدار می‌شود؟

(د) در روش RoPE، به جای افزودن مستقیم بردار موقعیت به بردارهای تعبیه‌شدهٔ توکن‌ها، بردارهای پرسش (Query) و کلید (Key) بر اساس موقعیت مکانی‌شان دوران داده می‌شوند. برای یک جفت‌بعد، ماتریس چرخش را به‌صورت زیر تعریف می‌کنیم:

$$R(\phi) = \begin{bmatrix} \cos\phi & -\sin\phi \\ \sin\phi & \cos\phi \end{bmatrix}$$

اگر $q, k \in \mathbb{R}^۲$ بوده و در موقعیت‌های مکانی m و n تعریف شوند:

$$\tilde{q}_m = R(m\theta)q, \quad \tilde{k}_n = R(n\theta)k$$

نشان دهید که ضرب داخلی آن‌ها ارائه‌دهندهٔ رابطهٔ زیر است:

$$\tilde{q}_m^\top \tilde{k}_n = q^\top R((n-m)\theta)k$$

این رابطه چه بینشی دربارهٔ نحوهٔ تزریق فاصلهٔ نسبی به امتیاز توجه (Attention Score) فراهم می‌کند؟

(ه) در حالت کلی چندبعدی، بردارهای $q, k \in \mathbb{R}^d$ به $d/۲$ زیربردار دوبعدی شکسته شده و هر زیربردار با فرکانس متناظر θ_i دوران داده می‌شود:

$$q = \left[q^{(۰)}, q^{(۱)}, \ldots, q^{(d/۲-۱)}\right]^\top, \quad k = \left[k^{(۰)}, k^{(۱)}, \ldots, k^{(d/۲-۱)}\right]^\top$$

آ) نشان دهید ضرب داخلی نهایی برابر است با:

$$\tilde{q}_m^\top \tilde{k}_n = \sum_{i=۰}^{d/۲-۱} \left(q^{(i)}\right)^\top R((n-m)\theta_i)k^{(i)}$$

ب) تفاوت‌های مبنایی میان سه رهیافت Absolute Positional Embedding، Sinusoidal PE و RoPE را از نظر جایگاه تزریق اطلاعات مکانی در پایپ‌لاین مدل (ورودی خام، بازنمایی Q/K، یا امتیاز توجه نهایی) مقایسه کنید.

ج) تحلیل کنید چرا RoPE در مقایسه با روش‌های تعبیهٔ مطلق موقعیت، ساختار منعطف‌تر و توانایی تعمیم بهتری در مواجهه با طول توالی‌های طولانی‌تر (Context Length Extrapolation) ارائه می‌دهد.

۶. تحلیل بنیادی یادگیری مقابله‌ای: از نظریهٔ اطلاعات تا بهینه‌سازی سخت‌افزاری

در یادگیری خودنظارتی (Self-Supervised Learning یا SSL) هدف استخراج بازنمایی‌های غنی و عام بدون نیاز به برچسب‌های دستی است. در این مسئله، پایه‌های نظری، ریاضی و مهندسی این روش‌ها به‌ویژه یادگیری مقابله‌ای و مدل SimCLR را تحلیل می‌کنیم.

بخش اول: مبانی بازنمایی و وظایف بهانه‌ای

(الف) تفاوت مبنایی روش‌های خودنظارتی نوین را با یادگیری مولد (Generative Learning) از منظر مدل‌سازی توزیع داده‌ها یعنی $p(x)$ تبیین کنید.

(ب) با تحلیل وظایف بهانه‌ای کلاسیک (Pretext Tasks) نظیر پیش‌بینی زاویهٔ چرخش تصویر (Rotation Prediction)، توضیح دهید چرا این مدل‌ها به جای استخراج ویژگی‌های معنایی عمیق (Semantic Features)، غالباً دچار سوگیری وظیفه‌محور (Task-specific bias) و استفاده از ویژگی‌های میان‌بر موضعی می‌شوند؟

(ج) در پروتکل ارزیابی سنجش خطی (Linear Probe)، فرض کنید مدلی روی وظیفهٔ بهانه‌ای چیدمان پازل (Jigsaw) به دقت بالای ۹۹٪ می‌رسد، اما هنگام ارزیابی با دسته‌بند خطی روی داده‌های ImageNet دقتی در حدود ۴۰٪ ارائه می‌دهد. این تضاد آشکار را چگونه تفسیر می‌کنید؟

بخش دوم: کالبدشکافی ریاضی زیان **InfoNCE** و اطلاعات متقابل

تابع هزینهٔ مقابله‌ای InfoNCE به‌صورت زیر تعریف می‌شود:

$$\mathcal{L} = -\mathbb{E}_X \left[\log \frac{\exp\left(s(f(x), f(x^+))/\tau\right)}{\exp\left(s(f(x), f(x^+))/\tau\right) + \sum_{j=1}^{N-1} \exp\left(s(f(x), f(x_j^-))/\tau\right)} \right]$$

که در آن x^+ نمونهٔ مثبت، x_j^- نمونه‌های منفی و $\tau > 0$ پارامتر دما است.

(د) برای یک نمونهٔ مرجع، امتیاز شباهت با نمونهٔ مثبت برابر با $s^+ = 0.9$ و امتیاز شباهت با سه نمونهٔ منفی به‌ترتیب $s_1 = 0.2$، $s_2 = 0.4$ و $s_3 = 0.5$ است. با فرض دمای $\tau = 0.1$، مقدار عددی زیان $\mathcal{L}$ را محاسبه کنید.
(راهنما: از تقریب‌های $e^9 \approx 8103$، $e^2 \approx 7$، $e^4 \approx 55$ و $e^5 \approx 148$ استفاده کنید.)

(ه) ثابت کنید اگر مدل کاملاً تصادفی عمل کند (یعنی تمام امتیازات شباهت s برای نمونه‌های مثبت و منفی با یکدیگر برابر باشند)، مقدار زیان همواره برابر با $\log(N)$ خواهد بود.

(و) با تکیه بر کران اطلاعات متقابل $\mathrm{MI}(f(x), f(x^+)) \geq \log(N) - \mathcal{L}$، تحلیل کنید که چرا افزایش تعداد نمونه‌های منفی (N) به بهبود کیفیت بازنمایی ویژگی‌ها می‌انجامد. این موضوع چه ارتباطی با تنگی کران پایین (Tightness of Lower Bound) دارد؟

بخش سوم: تحلیل مهندسی و مدیریت حافظه در **SimCLR**

کارایی معماری SimCLR به‌شدت به استفاده از دسته‌های بزرگ (Large Batch Size) وابسته است.

(ز) نقش لایهٔ پیش‌افکن غیرخطی $g(\cdot)$ را در حفظ اطلاعات معنایی درون فضای بازنمایی پایه (h) تحلیل کنید. چرا حذف این لایه پس از پایان پیش‌آموزش و استفادهٔ مستقیم از h برای وظایف پایین‌دستی ضروری است؟

(ح) فرض کنید می‌خواهیم مدل SimCLR را با اندازهٔ دستهٔ $N = 8192$ و ابعاد ویژگی $d = 2048$ آموزش دهیم. اگر هر عدد از نوع float32 (۴ بایت) باشد، حجم حافظهٔ مورد نیاز برای ذخیرهٔ «ماتریس قرابت» (Affinity Matrix) میان تمام

$۲N$ نمونه در یک گام آموزش را برحسب گیگابایت (GB) محاسبه کنید.
(راهنما: ابعاد ماتریس قرابت برابر با $۲N \times ۲N$ است و $۱GB = ۱۰۲۴^{۳}Bytes$ یا $۱۰^{۹}Bytes$ در نظر گرفته شود.)