به نام خدا

۱. مجموعه داده کوچک زیر شامل ۳ نقطه در فضای دوبعدی داده شده است:

$$x_۱ = -۱, \quad y_۱ = ۱$$

$$x_۲ = ۰, \quad y_۲ = ۰$$

$$x_۳ = ۱, \quad y_۳ = ۲$$

می‌خواهیم برازش خط $y = \omega_۰ + \omega_۱ x$ را پیدا کنیم.

(الف) ماتریس X و بردار y را تشکیل دهید و سپس ماتریس‌های $X^T X$ و $X^T y$ را محاسبه کنید.

(ب) با محاسبه معکوس ماتریس $X^T X$، مقادیر $\omega_۰$ و $\omega_۱$ را به دست آورید.

۲.(الف) فرض کنید برای یک مسئله رگرسیون، از تابع زیان Log-Cosh استفاده کرده‌ایم:

$$J(\omega) = \sum_{i=۱}^{n} \log\left(\cosh(x_i^T \omega - y_i)\right)$$

رابطه به‌روزرسانی پارامترهای ω را برای یک گام از الگوریتم گرادیان کاهشی به دست آورید.

(ب) فرض کنید در الگوریتم گرادیان کاهشی، نرخ یادگیری دیگر ثابت نیست و تابعی از شماره تکرار یعنی t است. سه تابع زیر برای تنظیم نرخ یادگیری در طول زمان پیشنهاد شده‌اند. تحلیل کنید که آیا هر کدام از این توابع برای استفاده به عنوان نرخ یادگیری مناسب هستند یا خیر؟ .

(۱) $\alpha_t = \frac{c}{t}$ (که c یک عدد ثابت مثبت است)

(۲) $\alpha_t = \frac{c}{t^۲}$

(۳) $\alpha_t = c \cdot t$

۳. در صورتی که تعداد ویژگی‌ها زیاد باشد، محاسبه معکوس ماتریس $(X^T X)^{-۱}$ از نظر محاسباتی سنگین است و به جای فرم بسته، از الگوریتم گرادیان کاهشی استفاده می‌کنیم.

(الف) تابع هزینه به فرم برداری ـ ماتریسی برابر است با $J(\omega) = \frac{۱}{۲}(y - X\omega)^T(y - X\omega)$. با محاسبه گرادیان این تابع، قانون به‌روزرسانی بردار وزن‌های ω را در الگوریتم گرادیان کاهشی با نرخ یادگیری α به دست آورید.

(ب) اکنون تابع هزینه با جریمه $L_۲$ را در نظر بگیرید: $J_{\text{Ridge}}(\omega) = \frac{۱}{۲}(y - X\omega)^T(y - X\omega) + \frac{\lambda}{۲}\omega^T\omega$. قانون به‌روزرسانی وزن‌ها را برای این حالت بنویسید.

۴. فرض کنید تعدادی داده مشاهده شده است و داده‌ها از رابطه $y = f(x) + \epsilon$ تولید شده‌اند، که در آن ϵ نویز با میانگین صفر ($\mathbb{E}[\epsilon] = ۰$) و واریانس ثابت $\text{Var}(\epsilon) = \sigma^۲$ است. اگر $\hat{f}(x)$ مدلی باشد که روی یک مجموعه داده آموزشی خاص برازش شده باشد:

(الف) با استفاده از ویژگی‌های امید ریاضی، اثبات کنید که امید خطای میانگین مربعات برای یک نقطه جدید x، به سه جزء زیر تجزیه می‌شود:

$$\mathbb{E}\left[(y - \hat{f}(x))^۲\right] = \left(\text{Bias}(\hat{f}(x))\right)^۲ + \text{Var}(\hat{f}(x)) + \sigma^۲$$

که در آن روابط بایاس و واریانس به صورت زیر تعریف می‌شوند:

$$\text{Bias}(\hat{f}(x)) = \mathbb{E}[\hat{f}(x)] - f(x)$$

$$\text{Var}(\hat{f}(x)) = \mathbb{E}\left[(\hat{f}(x) - \mathbb{E}[\hat{f}(x)])^۲\right]$$

(ب) به صورت تحلیلی توضیح دهید که هر یک از این سه جمله نشان‌دهنده چه مفهومی در مدل‌سازی هستند.

۵. در رگرسیون خطی، بردار پاسخ $y \in \mathbb{R}^n$ و ماتریس ویژگی‌های $X \in \mathbb{R}^{n \times d}$ را در اختیار داریم.

(الف) تابع هزینه رگرسیون خطی به صورت $J(\omega) = (y - X\omega)^T(y - X\omega)$ تعریف می‌شود. با استفاده از مشتق‌گیری برداری، ثابت کنید که وزن‌های بهینه از رابطه $\hat{\omega}_{\text{OLS}} = (X^TX)^{-۱}X^Ty$ به دست می‌آیند.

(ب) حال فرض کنید برای جلوگیری از بزرگ شدن وزن‌ها، جریمه $L_۲$ را به تابع هزینه اضافه می‌کنیم: $J_{\text{Ridge}}(\omega) = (y - X\omega)^T(y - X\omega) + \lambda\omega^T\omega$. با گرفتن گرادیان و برابر صفر قرار دادن آن، فرم بسته $\hat{\omega}_{\text{Ridge}}$ را بر حسب X، y، λ و ماتریس همانی I به دست آورید.

۶. فرض کنید یک متغیر ورودی یک‌بعدی x داریم و می‌خواهیم یک چندجمله‌ای از درجه d به شکل $\hat{y} = w_۰ + w_۱x + w_۲x^۲ + \cdots + w_dx^d$ را روی n نمونه داده برازش کنیم.

(الف) ماتریس طراحی X برای این مدل را تشکیل دهید.

(ب) وقتی درجه چندجمله‌ای d بزرگ می‌شود، دترمینان ماتریس X^TX به صفر نزدیک می‌شود. توضیح دهید چرا این اتفاق می‌افتد و این چگونه باعث بی‌ثباتی در محاسبه وزن‌ها می‌شود؟

۷. الگوریتم پرسپترون یکی از قدیمی‌ترین الگوریتم‌های یادگیری ماشین است. فرض کنید مجموعه‌داده‌ی ما خطی تفکیک‌پذیر است، یعنی بردار وزنی مانند ω^* با طول واحد ($||\omega^*|| = ۱$) وجود دارد که برای تمامی n داده‌ی آموزشی، شرط حاشیه‌ی $y_i(\omega^{*T}x_i) \geq \gamma$ برقرار است. همچنین فرض کنید طول بردارهای ویژگی کراندار است، یعنی برای تمام داده‌ها $||x_i|| \leq R$. در الگوریتم پرسپترون، وزن‌ها با مقدار اولیه $\omega^{(۰)} = ۰$ مقداردهی می‌شوند و در صورت دسته‌بندی اشتباه داده‌ی iام، به‌روزرسانی $\omega^{(t)} = \omega^{(t-۱)} + y_ix_i$ انجام می‌شود.

(الف) ثابت کنید که پس از t بار به‌روزرسانی خطا، کران پایین ضرب داخلی وزن‌ها با وزن بهینه به صورت $\omega^{(t)T}\omega^* \geq t\gamma$ است.

(ب) ثابت کنید که کران بالای نرم مجذور وزن‌ها به صورت $||\omega^{(t)}||^۲ \leq tR^۲$ است.

(ج) با ترکیب دو نامعادله‌ی بالا، قضیه همگرایی پرسپترون را اثبات کنید؛ یعنی نشان دهید که این الگوریتم حداکثر پس از $\frac{R^۲}{\gamma^۲}$ مرحله، همگرا می‌شود.

۸.(الف) تابع زیان پرسپترون به صورت $J(\omega) = \sum_{i \in \mathcal{M}} -y_i(\omega^T x_i)$ تعریف می‌شود که در آن $\mathcal{M}$ مجموعه اندیس داده‌هایی است که توسط مدل اشتباه دسته‌بندی شده‌اند. با محاسبه‌ی گرادیان این تابع، نشان دهید که چگونه قانون به‌روزرسانی پرسپترون (که در سوال قبل دیدید) همان الگوریتم گرادیان کاهشی SGD روی این تابع زیان است.

(ب) مجموعه‌داده‌ی مسئله XOR را در فضای دوبعدی در نظر بگیرید که شامل ۴ نقطه‌ی زیر است:

$$x_۱ = \begin{bmatrix} ۰ \\ ۰ \end{bmatrix}, y_۱ = -۱ \qquad x_۲ = \begin{bmatrix} ۱ \\ ۰ \end{bmatrix}, y_۲ = +۱$$

$$x_۳ = \begin{bmatrix} ۰ \\ ۱ \end{bmatrix}, y_۳ = +۱ \qquad x_۴ = \begin{bmatrix} ۱ \\ ۱ \end{bmatrix}, y_۴ = -۱$$

با نوشتن دستگاه نامعادلات خطی، به صورت ریاضی اثبات کنید که هیچ بردار وزن ω و عرض از مبدأ b نمی‌تواند این داده‌ها را به درستی دسته‌بندی کند.

۹. رگرسیون لاجستیک در حالت Binary Classification از تابع سیگموید استفاده می‌کند. تابع سیگموید به صورت $\sigma(z) = \frac{۱}{۱+e^{-z}}$ تعریف می‌شود.

(الف) ابتدا ثابت کنید که مشتق تابع سیگموید برحسب z برابر است با: $\sigma'(z) = \sigma(z)(۱ - \sigma(z))$.

(ب) فرض کنید برچسب‌ها $y_i \in \{۰, ۱\}$ باشند. تابع زیان برای یک نمونه $L(\omega) = -y \log(\hat{y}) - (۱ - y) \log(۱ - \hat{y})$ است که در آن $\hat{y} = \sigma(\omega^T x)$. با استفاده از قاعده زنجیره‌ای و نتیجه‌ی بخش الف، گرادیان $\nabla_\omega L$ را محاسبه کنید.

(ج) رابطه‌ی به‌دست آمده برای گرادیان رگرسیون لاجستیک را با گرادیان رگرسیون خطی عادی مقایسه کنید. چه شباهت ساختاری بین آن‌ها وجود دارد؟

۱۰. برای تعمیم رگرسیون لاجستیک به حالت چندکلاسه با K کلاس، از تابع سافت‌مکس (Softmax) استفاده می‌کنیم. احتمال تعلق داده‌ی x به کلاس k برابر است با:

$$\hat{y}_k = P(Y = k|x) = \frac{\exp(\omega_k^T x)}{\sum_{j=۱}^{K} \exp(\omega_j^T x)}$$

همچنین تابع زیان برای یک نمونه داده به فرم $L = -\sum_{k=۱}^{K} y_k \log(\hat{y}_k)$ تعریف می‌شود (که در آن فقط برای کلاس واقعی $y_c = ۱$ و برای بقیه کلاس‌ها $y_k = ۰$ است).

(الف) مشتق خروجی سافت‌مکس $\hat{y}_k$ را نسبت به مقدار ورودی کلاس j یعنی $z_j = \omega_j^T x$ محاسبه کنید. (باید دو حالت $k = j$ و $k \neq j$ را جداگانه بررسی کنید).

(ب) با استفاده از نتیجه‌ی بخش قبل، بردار گرادیان تابع زیان L را نسبت به بردار وزن‌های کلاس خاص c یعنی ω_c به دست آورید و نشان دهید که برابر با $(\hat{y}_c - y_c)x$ است.

۱۱. طبق تئوری تصمیم آماری، دسته‌بند بهینه‌ی بیز (Bayes Optimal Classifier) مدلی است که خطای دسته‌بندی را کمینه می‌کند.

(الف) ثابت کنید قانونی که به هر داده x، کلاسی را تخصیص می‌دهد که احتمال $P(Y = y|X = x)$ برای آن بیشینه است، کمترین نرخ خطای ممکن را در میان تمامی دسته‌بندها دارد.

(ب) اگر دسته‌بند بیز بهینه‌ترین مدل است، چرا در مسائل واقعی نمی‌توانیم مستقیما از آن استفاده کنیم؟

(ج) الگوریتم Naive Bayes چه فرضی را به مدل اضافه می‌کند تا مشکل مطرح شده در بخش قبل حل شود؟

۱۲. یک سیستم فیلتر هرزنامه بر اساس مدل بیز ساده (Naive Bayes) در اختیار داریم. دایره لغات ما شامل ۵ کلمه است: $V = \{w_۱, w_۲, w_۳, w_۴, w_۵\}$. مجموعه داده‌ی آموزشی شامل ۴ پیام است که بردار ویژگی آن‌ها (تعداد تکرار هر کلمه در پیام) در جدول زیر آورده شده است:

شماره پیام	(win) $w_۱$	(money) $w_۲$	(free) $w_۳$	(hello) $w_۴$	(friend) $w_۵$	کلاس (y)
۱	۱	۱	۰	۰	۰	Spam
۲	۱	۱	۱	۰	۰	Spam
۳	۰	۰	۰	۱	۱	Ham
۴	۰	۱	۰	۰	۱	Ham

پیامک جدیدی دریافت کرده‌ایم که فقط شامل کلمات $w_۳$ و $w_۵$ است (یعنی بردار ویژگی آن $x_{new} = [۰, ۰, ۱, ۰, ۱]$ است).

(الف) احتمال پیشین هر کلاس، یعنی $P(\text{Spam})$ و $P(\text{Ham})$ را بنویسید. سپس نشان دهید که اگر از فرمول پایه (بدون هموارسازی) استفاده کنیم، احتمال‌های شرطی $P(x_{new}|\text{Spam})$ و $P(x_{new}|\text{Ham})$ هر دو برابر صفر می‌شوند. این مشکل چه نام دارد؟

(ب) برای رفع این مشکل، از Laplace Smoothing با پارامتر $\alpha = ۱$ استفاده کنید. مقادیر $P(w_۳|\text{Spam})$، $P(w_۵|\text{Spam})$، $P(w_۳|\text{Ham})$ و $P(w_۵|\text{Ham})$ را محاسبه کنید.

(ج) با استفاده از مقادیر به‌دست‌آمده در بخش قبل، امتیاز نهایی تعلق پیام جدید به هر کلاس را محاسبه کنید. بر اساس این اعداد، مدل بیز ساده این پیام را در کدام دسته طبقه‌بندی می‌کند؟