به نام خدا

۱. فرض کنید $X_1, X_2, \dots, X_n$ یک نمونه‌ی تصادفی مستقل از توزیع نرمال $N(\mu, \sigma^2)$ باشد.
تخمین‌گر $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ را در نظر بگیرید.

(الف) با استفاده از خطی‌بودن عملگر امید ریاضی، نشان دهید که $\bar{X}$ یک تخمین‌گر ناااریب برای μ است.

(ب) با فرض استقلال X_iها، واریانس $\mathrm{Var}(\bar{X})$ را بر حسب σ^2 و n محاسبه کنید.

۲. تخمین‌گر $S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$ را در نظر بگیرید. می‌دانیم که $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{(n-1)}$.

(الف) با استفاده از $\mathbb{E}(\chi^2_{(k)}) = k$، نشان دهید که S^2 یک تخمین‌گر ناااریب برای σ^2 است.

(ب) با استفاده از $\mathrm{Var}(\chi^2_{(k)}) = 2k$، واریانس $\mathrm{Var}(S^2)$ را بر حسب σ^4 و n به دست آورید.

۳. خانواده‌ای از تخمین‌گرها را به صورت $\hat{\mu}_a = a\bar{X}$ تعریف می‌کنیم که در آن a یک عدد ثابت است.

(الف) شرط لازم برای ناااریب بودن $\hat{\mu}_a$ نسبت به μ را بیابید و مقدار a را تعیین کنید.

(ب) برای مقدار a به‌دست‌آمده در بخش قبل، واریانس $\mathrm{Var}(\hat{\mu}_a)$ را محاسبه کنید.

(ج) اگر $a = 2$ را در نظر بگیریم، مقدار میانگین مربعات خطا یعنی $\mathrm{MSE}(\hat{\mu}_a) = \mathrm{Var}(\hat{\mu}_a) + \mathrm{Bias}^2$ را بر حسب σ^2، n و μ به دست آورید.

۴. فرض کنید M مدل پایه‌ی $f_1(X), \dots, f_M(X)$ در دسترس است. این مدل‌ها هم‌توزیع بوده، هر یک دارای واریانس σ^2 و بایاس یکسان هستند، و ضریب همبستگی زوجی هر دو مدل متمایز برابر ρ می‌باشد. مدل تجمعی حاصل از کیسه‌گذاری به صورت $f_{\mathrm{bag}}(X) = \frac{1}{M}\sum_{i=1}^{M} f_i(X)$ تعریف می‌شود.

(الف) رابطه‌ی زیر را برای واریانس مدل تجمعی اثبات کنید:

$$\mathrm{Var}\big(f_{\mathrm{bag}}(X)\big) \;=\; \rho\,\sigma^2 \;+\; \frac{1-\rho}{M}\,\sigma^2.$$

همچنین نشان دهید که بایاس مدل تجمعی دقیقاً با بایاس هر یک از مدل‌های پایه برابر است. حد واریانس را هنگامی که $M \to \infty$ محاسبه کنید و توضیح دهید که چرا افزایش صرفِ تعداد درخت‌ها نمی‌تواند واریانس را به صفر برساند. برای $\sigma^2 = 1$، $\rho = 0.6$ و $M \in \{10, 100, \infty\}$، مقدار عددی واریانس را به‌دست آورید.

(ب) با استناد به رابطه‌ی قسمت قبل، تشریح کنید که چرا در جنگل تصادفی، علاوه بر نمونه‌گیری bootstrap، در هر گره تنها زیرمجموعه‌ای تصادفی به اندازه‌ی m از کل d ویژگی موجود، برای انجام تقسیم در نظر گرفته می‌شود. اثر کاهش m را بر ρ و بر واریانسِ هر درخت منفرد تحلیل نمایید و استدلال کنید که m یک ابرپارامتر با ماهیت مصالحه‌ای است و انتخاب هرچه کوچک‌تر آن لزوماً بهینه نیست.

(ج) در روش نمونه‌گیری bootstrap با جایگذاری از میان n نمونه، ثابت کنید احتمال آنکه یک نمونه‌ی معیّن در یک کیسه حضور نداشته باشد، برابر $\left(1-\frac{1}{n}\right)^n$ است. نشان دهید که این مقدار با $n \to \infty$ به $e^{-1} \approx 0.368$ همگرا می‌شود. بر اساس این نتیجه، برآورد خطای خارج‌ازکیسه (Out-of-Bag) را تعریف کنید. سپس با مقایسه‌ی نسبت داده‌هایی که هر مدل بر روی آنها آموزش می‌بیند با نسبت مشابه در اعتبارسنجی متقاطع Kـ تایی، مشخص نمایید که برآورد OOB از این حیث به کدام مقدار K نزدیک‌تر است و مزیت محاسباتی آن نسبت به اجرای کامل اعتبارسنجی متقاطع را توضیح دهید.

۵. به‌طور مختصر و مستدل به پرسش‌های زیر پاسخ دهید:

(الف) چرا کیسه‌گذاری برای درخت‌های عمیق هرس‌نشده بسیار کارآمد است، در حالی که برای رگرسیون خطی تأثیر چشمگیری ندارد؟

(ب) آیا کیسه‌گذاری می‌تواند بایاس مدل را کاهش دهد؟ در صورتی که مدل پایه از بایاس بالایی برخوردار باشد، چه انتظاری می‌توان داشت؟

(ج) به چه دلیل درخت‌های یک جنگل تصادفی را می‌توان کاملاً موازی آموزش داد، ولی این امکان برای مدل‌های Boosting میسّر نیست؟

۶. الگوریتم AdaBoost را برای مسائل دسته‌بندی دوکلاسه با برچسب‌های $y_i \in \{-1,+1\}$ در نظر بگیرید. در تکرار tام، توزیع وزن‌ها D_t بوده، یادگیرنده‌ی ضعیف h_t با کمینه‌سازی خطای وزن‌دار $\epsilon_t = \sum_i D_t(i)\,\mathbb{I}\{h_t(x_i) \neq y_i\}$ انتخاب می‌شود. سپس وزن‌ها طبق قاعده‌ی $D_{t+1}(i) \propto D_t(i)\, e^{-\alpha_t y_i h_t(x_i)}$ به‌روزرسانی می‌گردند و سرانجام مدل نهایی به صورت $H(x) = \operatorname{sign}\big(\sum_{t=1}^{T} \alpha_t h_t(x)\big)$ تعریف می‌شود.

(الف) ضریب نرمال‌سازی در تکرار t را با $Z_t = \sum_i D_t(i)\, e^{-\alpha_t y_i h_t(x_i)}$ نمایش دهید. اثبات کنید که $Z_t = (1-\epsilon_t)e^{-\alpha_t} + \epsilon_t e^{\alpha_t}$ و با کمینه‌سازی Z_t نسبت به α_t، رابطه‌ی

$$\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$$

را به‌دست آورید. تفسیر کنید که چرا وقتی $\epsilon_t \to 0$، مقدار $\alpha_t \to \infty$ و وقتی $\epsilon_t = 1/2$، مقدار $\alpha_t = 0$ می‌شود؛ همچنین بیان کنید که در حالت $\epsilon_t > 1/2$ چه رخ می‌دهد.

(ب) ثابت کنید که پس از به‌روزرسانی وزن‌ها، خطای وزن‌دار همان یادگیرنده‌ی h_t تحت توزیع جدید D_{t+1} دقیقاً برابر $\frac{1}{2}$ خواهد بود. این ویژگی چه تضمینی در مورد عدم تکرار یادگیرنده‌ی ضعیف یکسان در دور بعدی ارائه می‌دهد؟

(ج) کران زیر را برای خطای آموزش مدل نهایی اثبات کنید:

$$\frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\{H(x_i) \neq y_i\} \;\leq\; \prod_{t=1}^{T} Z_t \;=\; \prod_{t=1}^{T} 2\sqrt{\epsilon_t(1-\epsilon_t)}.$$

سپس با تعریف $\gamma_t = \frac{1}{2} - \epsilon_t$، نشان دهید که کران مذکور از $\exp\!\left(-2\sum_{t=1}^{T}\gamma_t^2\right)$ کوچک‌تر است و نتیجه بگیرید که

اگر برای همه‌ی یادگیرنده‌های ضعیف شرط $\gamma_t \geq \gamma > 0$ برقرار باشد، خطای آموزش به‌صورت نمایی نسبت به T به صفر میل می‌کند. (راهنمایی: از نامساوی $\mathbb{I}\{u \leq 0\} \leq e^{-u}$ استفاده کنید.)

(د) نشان دهید که AdaBoost معادل کمینه‌سازی گام‌به‌گامِ تابع هزینه‌ی نمایی $\mathbb{E}\big[e^{-yf(x)}\big]$ است و کمینه‌کننده‌ی جمعیتی این تابع به صورت

$$f^*(x) = \frac{1}{2} \ln \frac{P(y=+1 \mid x)}{P(y=-1 \mid x)}$$

به‌دست می‌آید. با استناد به این نتیجه، توضیح دهید که چرا AdaBoost نسبت به نویز برچسب حساس‌تر از روش‌های مبتنی بر بیشینه‌ی درست‌نمایی لجستیک عمل می‌کند و یک راهکار عملی برای کاهش این حساسیت پیشنهاد کنید.

(ه) مجموعه‌ی چهار نمونه‌ی یک‌بعدی زیر را در نظر بگیرید:

$$(x, y) \in \{(1, +1),\ (2, +1),\ (3, -1),\ (4, +1)\},$$

و فرض کنید که یادگیرنده‌های ضعیف، طبقه‌بندهای تک‌آستانه‌ای از دو شکل $h(x) = \operatorname{sign}(x - \theta)$ یا $h(x) = -\operatorname{sign}(x - \theta)$ هستند. دو تکرار نخست الگوریتم AdaBoost را به‌طور کامل پیاده‌سازی کنید و در هر تکرار، h_t، ϵ_t، α_t و توزیع وزن‌های به‌روزشده را مشخص نمایید. سپس بررسی کنید که آیا مدل نهایی H_2 تمامی چهار نمونه را به‌درستی طبقه‌بندی می‌کند یا خیر.

۷. یک دسته‌بند دودویی را در نظر بگیرید که به هر نمونه‌ی x یک امتیاز حقیقی $s(x) \in \mathbb{R}$ نسبت می‌دهد و پیش‌بینی نهایی با اعمال آستانه‌ی τ به‌صورت $\hat{y} = \mathbb{I}\{s(x) > \tau\}$ ساخته می‌شود. فرض کنید $S^+ = s(X) \mid y = 1$ و $S^- = s(X) \mid y = 0$ توزیع‌های پیوسته دارند و $\pi = P(y = 1)$ شیوع کلاس مثبت است. نرخ مثبت درست و نرخ مثبت کاذب را با $\mathrm{TP}(\tau) = P(S^+ > \tau)$ و $\mathrm{FP}(\tau) = P(S^- > \tau)$ نشان می‌دهیم.

(الف) اثبات کنید که سطح زیر منحنی ROC برابر است با

$$\mathrm{AUC} \;=\; \int_0^1 \mathrm{TPR}\big(\mathrm{FPR}^{-1}(u)\big)\, du \;=\; P\big(S^+ > S^-\big),$$

یعنی احتمال آنکه یک نمونه‌ی مثبتِ تصادفی امتیاز بالاتری از یک نمونه‌ی منفیِ تصادفی دریافت کند. (راهنمایی: با تغییر متغیر $u = \mathrm{FPR}(\tau)$ و نوشتن TPR به‌صورت یک امید ریاضی شرطی شروع کنید.)

(ب) فرض کنید $g : \mathbb{R} \to \mathbb{R}$ یک تابع اکیداً صعودی باشد و امتیازها را با $s'(x) = g(s(x))$ جایگزین کنیم. نشان دهید که AUC تغییر نمی‌کند. با استفاده از این نتیجه توضیح دهید که چرا AUC هیچ اطلاعاتی درباره‌ی calibration مدل (یعنی این که آیا $s(x) \approx P(y = 1 \mid x)$ برقرار است یا نه) ارائه نمی‌دهد، و چرا دو مدل با AUC یکسان می‌توانند log-loss کاملاً متفاوتی داشته باشند.

(ج) نشان دهید که دقت مثبت (Precision) در آستانه‌ی τ برابر است با

$$\mathrm{Precision}(\tau) \;=\; \frac{\pi\, \mathrm{TPR}(\tau)}{\pi\, \mathrm{TPR}(\tau) + (1 - \pi)\, \mathrm{FPR}(\tau)}.$$

با استفاده از این رابطه استدلال کنید که اگر تعداد نمونه‌های منفی مجموعه‌ی آزمون را ۱۰۰ برابر کنیم (بدون تغییر توزیع‌های شرطی S^+ و S^-)، منحنی ROC و مقدار AUC دقیقاً بدون تغییر می‌مانند، اما منحنی Precision-Recall به‌شدت افت می‌کند. مقدار عددی Precision را برای $\mathrm{TPR} = 0.9$، $\mathrm{FPR} = 0.05$ در دو حالت $\pi = 0.5$ و $\pi = 0.001$ محاسبه و مقایسه کنید.

(د) با تکیه بر بخش پیشین توضیح دهید که در یک مسئله‌ی تشخیص رویداد نادر (مثلاً تشخیص یک بیماری با شیوع ٪۰٫۱) کدام‌یک از دو معیار AUC و Average Precision (سطح زیر منحنی Precision-Recall) معیار مناسب‌تری برای مقایسه‌ی مدل‌هاست و چرا. همچنین توضیح دهید که چرا گزارش کردن $\text{AUC} = ۰٫۹۹$ در چنین مسئله‌ای می‌تواند گمراه‌کننده باشد.

۸. مجموعه‌ی داده‌ی آموزشی زیر را در نظر بگیرید. هدف، پیش‌بینی برچسب دودویی y است. ویژگی ID یک شناسه‌ی یکتا برای هر نمونه است.

ID	هوا	رطوبت	باد	y
۱	آفتابی	زیاد	ضعیف	$-$
۲	آفتابی	زیاد	قوی	$-$
۳	ابری	زیاد	ضعیف	$+$
۴	بارانی	معمولی	ضعیف	$+$
۵	بارانی	معمولی	ضعیف	$+$
۶	بارانی	معمولی	قوی	$-$
۷	ابری	معمولی	قوی	$+$
۸	آفتابی	معمولی	ضعیف	$+$

(الف) آنتروپی ریشه $H(y)$ را محاسبه کنید. سپس بهره‌ی اطلاعات $\text{IG}(y, A) = H(y) - \sum_v \frac{|S_v|}{|S|} H(y \mid A = v)$ را برای هر سه ویژگی «هوا»، «رطوبت» و «باد» محاسبه کرده و ویژگی ریشه را انتخاب کنید. سپس درخت تصمیم کامل را با نمایش تمام محاسبات هر سطح رسم کنید. (در صورت تساوی تعداد برچسب‌ها در یک برگ، برچسب $+$ را انتخاب کنید.)

(ب) ثابت کنید که برای ویژگی ID که در هر نمونه مقداری یکتا دارد، همواره $\text{IG}(y, \text{ID}) = H(y)$ برقرار است، یعنی این ویژگی بیشترین بهره‌ی ممکن را دارد. توضیح دهید که چرا الگوریتم ID3 در نتیجه‌ی این خاصیت، درختی با خطای آموزش صفر و خطای تعمیم فاجعه‌بار می‌سازد، و این پدیده چه ارتباطی با مفهوم بیش‌برازش دارد.

(ج) معیار نسبت بهره (Gain Ratio) به‌صورت

$$\text{GainRatio}(y, A) = \frac{\text{IG}(y, A)}{\text{SplitInfo}(A)}, \qquad \text{SplitInfo}(A) = -\sum_v \frac{|S_v|}{|S|} \log_۲ \frac{|S_v|}{|S|}$$

تعریف می‌شود. مقدار SplitInfo و GainRatio را برای ویژگی ID و ویژگی «هوا» محاسبه کنید و با مقایسه‌ی این دو عدد بررسی کنید که آیا نسبت بهره در این مجموعه‌ی داده‌ی کوچک واقعاً مشکل بخش قبل را برطرف می‌کند یا نه. سپس به‌طور کلی نشان دهید

$$\text{GainRatio}(y, \text{ID}) = \frac{H(y)}{\log_۲ n},$$

و با استفاده از آن مشخص کنید که از چه اندازه‌ی نمونه‌ی n به بعد این معیار ویژگی شناسه را کنار می‌گذارد. همچنین توضیح دهید که نسبت بهره خود چه ضعفی دارد (به رفتار آن وقتی SplitInfo بسیار کوچک است توجه کنید) و چرا معمولاً آن را با یک شرط کمکی، مثلاً محدود کردن انتخاب به ویژگی‌هایی که IG آن‌ها بالاتر از میانگین است، به کار می‌برند.

(د) ثابت کنید که برای هر ویژگی A همواره $\text{IG}(y, A) \geq ۰$ برقرار است، و تساوی برقرار است اگر و تنها اگر y و A مستقل باشند. (راهنمایی: IG همان اطلاعات متقابل $I(y; A)$ است؛ از تقعّر تابع آنتروپی و نامساوی ینسن استفاده کنید.) نتیجه بگیرید که یک تقسیم هرگز آنتروپی مورد انتظار را افزایش نمی‌دهد، و توضیح دهید که چرا با وجود این، «همیشه تقسیم کردن» راهبرد درستی نیست.

۹.(الف) یک درخت رگرسیون با معیار خطای مربعی را در نظر بگیرید. برای برگ t با مجموعه‌ی نمونه‌های S_t، ثابت کنید که مقدار ثابتِ بهینه‌ای که $\sum_{i\in S_t}(y_i - c)^2$ را کمینه می‌کند برابر میانگین $\bar{y}_t$ است. سپس ثابت کنید که تقسیم هر گره به دو فرزند t_L و t_R هرگز مجموع مربعات خطای آموزش را افزایش نمی‌دهد، یعنی $\mathrm{SSE}(t) \geq \mathrm{SSE}(t_L) + \mathrm{SSE}(t_R)$ برقرار است، و شرط لازم و کافی برای برقراری تساوی را مشخص کنید. این نتیجه چه پیامدی برای استفاده از خطای آموزش به‌عنوان معیار توقف رشد درخت دارد؟

(ب) دو معیار ناخالصی برای دسته‌بندی دودویی با احتمال p برای کلاس مثبت را در نظر بگیرید:

$$H(p) = -p\log_2 p - (1-p)\log_2(1-p), \qquad G(p) = 2p(1-p).$$

نشان دهید که هر دو تابع در $[0, 1]$ مقعّرند، در $p = 0, 1$ صفر و در $p = 1/2$ بیشینه می‌شوند. با بسط تیلور حول $p = 1/2$ نشان دهید که $H(p) \approx 1 - \frac{2}{\ln 2}(p - \frac{1}{2})^2$ و $G(p) = \frac{1}{2} - 2(p - \frac{1}{2})^2$ برقرار است، و نتیجه بگیرید که این دو معیار تا مرتبه‌ی دوم متناسب‌اند. سپس توضیح دهید که چرا «نرخ خطای دسته‌بندی» $\min(p, 1-p)$ با وجود مقعّر بودن، معیار مناسبی برای رشد درخت نیست (یک مثال عددی بسازید که در آن یک تقسیم مفید، کاهش نرخ خطای صفر بدهد ولی بهره‌ی اطلاعات مثبت باشد).

(ج) هرس هزینه‌ـ‌پیچیدگی با معیار $R_\alpha(T) = R(T) + \alpha|T|$ انجام می‌شود که در آن $|T|$ تعداد برگ‌ها است. برای گره‌ی داخلی t با زیردرخت T_t، ثابت کنید که مقدار بحرانی α که در آن جمع‌کردن T_t به یک برگ به‌صرفه می‌شود برابر است با

$$\alpha_{\mathrm{eff}}(t) \;=\; \frac{R(t) - R(T_t)}{|T_t| - 1}.$$

سپس استدلال کنید که با افزایش پیوسته‌ی α از صفر تا بی‌نهایت، دنباله‌ای متناهی و تودرتو از زیردرخت‌های بهینه به دست می‌آید که با درخت کامل شروع و به ریشه ختم می‌شود. توضیح دهید که α نهایی چگونه با اعتبارسنجی متقاطع انتخاب می‌شود.

(د) مسئله‌ی دسته‌بندی دودویی در $\mathbb{R}^2$ را در نظر بگیرید که در آن مرز بهینه خط $x_2 = x_1$ است. توضیح دهید که چرا یک درخت با تقسیم‌های محورموازی نمی‌تواند این مرز را دقیقاً بازنمایی کند، و نشان دهید که برای رسیدن به خطای حداکثر ϵ روی مربع واحد، عمق درخت باید از مرتبه‌ی $\Theta(\log(1/\epsilon))$ باشد. سپس دو راهکار برای رفع این محدودیت پیشنهاد دهید و اثر هر یک را بر تفسیرپذیری مدل بررسی کنید.